

N° Ordre :..... /2026

Mémoire de Projet de Fin d'Etudes

Présenté pour obtenir la
Licence Science de la Santé en :
Technologue en Instrumentation et Maintenance Biomédicales

Identification automatique des asynchronies patient-ventilateur

Réalisé par :

Mr. LEKCHIRI Mohammed

Encadré par :

Pr. LYAZIDI Aissam

Soutenu publiquement le 03 Juin 2026

Devant le jury :

Pr. HILAL MOHAMMED

Pr. ELBAYDAOUI REDOUANE

Pr. LYAZIDI AISSAM (encadrant)

Année universitaire : 2025/2026

*La volonté permet de grimper sur les cimes,
sans volonté on reste au pied de la montagne.*

- Victor Hugo

DÉDICACES

À mes parents,

*À la lumière de la vie qui a éclairé mon chemin et dissipé mes doutes.
Vous êtes le souffle originel qui a nourri mes ambitions, et la force bienveillante
qui ne m'a jamais fait défaut. Si la volonté m'a permis de gravir la montagne,
c'est votre amour inconditionnel et vos sacrifices silencieux qui m'ont donné
l'énergie d'en atteindre le sommet.*

*À ma mère, mon refuge et ma source inépuisable de tendresse.
À mon père, ma boussole et mon pilier inébranlable.*

*Ce modeste travail n'est que le reflet de ce que vous m'avez offert :
la patience de comprendre le monde et le courage d'y avancer.
Que ce mémoire soit l'hommage de mon immense gratitude.*

REMERCIEMENTS

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué à la réalisation de ce projet de fin d'études.

Tout d'abord, je remercie chaleureusement mes encadrants pédagogiques, mon encadrant le professeur Aissam Lyazidi et le professeur Elmaati Essoukaki, pour leur précieuse guidance, leurs conseils avisés et leur soutien constant tout au long de cette recherche. Leurs compétences et leur expertise ont été d'une aide inestimable pour mener à bien ce projet.

Je souhaite également remercier l'ensemble du corps professoral et administratif de l'Institut Supérieur des Sciences de la Santé (ISSS), pour avoir fourni un environnement académique stimulant et enrichissant. Vos enseignements et votre accompagnement m'ont permis d'acquérir les connaissances et compétences nécessaires en instrumentation et maintenance biomédicale pour entreprendre ce travail. Je tiens à exprimer ma gratitude à mes professeurs pour m'avoir incité à me dépasser en me faisant bénéficier de leurs expériences et compétences.

Un remerciement particulier s'adresse à toute l'équipe de la Société Commerciale de Représentation Industrielle et Médicale (SCRIM) à Casablanca, qui m'a accueilli lors de mon stage. Je remercie tout particulièrement Monsieur Fouad El Ouafi, responsable technique, pour son accueil et son encadrement.

Je tiens à adresser ma reconnaissance la plus sincère et toute spéciale à Hamza Zeroual et Mehdi Ghiyat, de véritables experts d'intervention sur le terrain. J'ai énormément appris à leurs côtés ; leur pédagogie, leur patience et le généreux partage de leur savoir-faire technique m'ont permis de lier la théorie académique à la réalité exigeante du terrain dans d'excellentes conditions.

Enfin, mes pensées les plus affectueuses vont à ma famille, et particulièrement à mes parents, pour leur soutien moral et matériel indéfectible, ainsi que pour leurs encouragements constants. Leur amour et leur confiance en moi ont été une source de motivation permanente.

À tous, je vous dis sincèrement merci.

RÉSUMÉ

La ventilation mécanique est une intervention vitale en soins intensifs, mais son efficacité repose grandement sur une interaction optimale entre le patient et le respirateur. La synchronisation patient-ventilateur demeure un défi clinique majeur, car les asynchronies peuvent entraîner un inconfort, une augmentation du travail respiratoire et une prolongation de la durée de ventilation.

Ce document explore les différents types d'asynchronies, telles que les efforts inefficaces, les doubles déclenchements et les retards de cyclage. Ces anomalies surviennent lorsqu'il y a un décalage entre la commande neurologique respiratoire du patient et l'assistance pneumatique fournie par la machine, affectant directement la qualité de la prise en charge.

Afin d'optimiser cette interaction, diverses stratégies de monitoring et d'adaptation sont analysées. Des technologies avancées, allant de l'analyse fine des courbes de pression et de débit à l'utilisation d'outils spécifiques comme le monitoring de l'activité électrique du diaphragme (EAdi) ou de la pression oesophagienne, permettent aujourd'hui une détection plus précoce et précise des défauts de synchronisation.

En conclusion, l'amélioration de la synchronisation patient-ventilateur est essentielle pour réduire les complications associées à la ventilation artificielle. L'intégration de ces outils de surveillance permet une gestion plus proactive et personnalisée des réglages du ventilateur, favorisant ainsi le confort du patient, accélérant le processus de sevrage et améliorant globalement le pronostic clinique.

SUMMARY

Mechanical ventilation is a life-saving intervention in intensive care, but its effectiveness relies heavily on optimal interaction between the patient and the ventilator. Patient-ventilator synchronization remains a major clinical challenge, as asynchronies can lead to discomfort, increased work of breathing, and prolonged duration of mechanical ventilation.

This document explores the different types of asynchronies, such as ineffective efforts, double triggering, and cycling delays. These anomalies occur when there is a mismatch between the patient's neural respiratory drive and the pneumatic assistance provided by the machine, directly affecting the quality of patient care.

To optimize this interaction, various monitoring and adaptation strategies are analyzed. Advanced technologies, ranging from the detailed analysis of pressure and flow waveforms to the use of specific tools like Electrical activity of the diaphragm (EAdi) or esophageal pressure monitoring, now allow for earlier and more accurate detection of synchronization issues.

In conclusion, improving patient-ventilator synchronization is essential to reduce complications associated with artificial ventilation. Integrating these monitoring tools enables more proactive and personalized management of ventilator settings, thereby promoting patient comfort, accelerating the weaning process, and improving overall clinical outcomes.

Table des matières

DÉDICACES	ii
REMERCIEMENTS	iii
RÉSUMÉ	iv
SUMMARY	v
Table des figures	1
Liste des tableaux	2
Liste des Sigles et Abréviations	3
INTRODUCTION GÉNÉRALE	4
1 Lieu de stage	6
1.1 Présentation de la Société Commerciale de Représentation Industrielle et Médicale (SCRIM)	6
1.1.1 Présentation de l'entreprise	6
1.1.2 Organigramme de l'entreprise	6
1.1.3 Le Service Technique et Biomédical	6
1.2 Bilan des Activités	7
1.2.1 Installation et Mise en Service	7
1.2.2 Maintenance Préventive et Tests de Sécurité	8
1.2.3 Diagnostic et Maintenance Corrective	8
1.2.4 Formation des Utilisateurs et Traçabilité	9
1.2.5 Conclusion	9
2 Automatisation par l'Intelligence Artificielle	10
2.1 Le Deep Learning comme solution de rupture	10
2.1.1 Limites des algorithmes déterministes classiques	10
2.1.2 La pertinence de l'Apprentissage Profond (Deep Learning)	10
2.2 Démarche Technologique et Scientifique du Projet	11
2.2.1 1. Extraction et traitement des signaux bruts	11
2.2.2 2. Exploitation des architectures Deep Learning	11
2.2.3 3. Classification et diagnostic en temps réel	11
2.3 Impacts et Bénéfices Cliniques Attendus	12
2.3.1 Monitoring continu et Index d'Asynchronie	12
2.3.2 Réduction de la charge cognitive des équipes	12
2.3.3 Personnalisation du traitement et amélioration du pronostic	12

3	État de l'art des Asynchronies Patient-Ventilateur	13
3.1	Caractérisation des asynchronies	13
3.1.1	Le Double Déclenchement (Double Triggering)	13
3.1.2	L'Effort Inefficace (Ineffective Effort)	14
3.1.3	Les anomalies de cyclage (Prématuré et Tardif)	15
3.1.4	L'asynchronie de flux (Flow Starvation / Inadequate Flow)	17
3.1.5	Les Fuites (Leaks) et l'Auto-déclenchement	17
3.2	Analyse du signal ventilatoire (Débit/Pression)	17
3.2.1	La courbe de Pression-Temps ($P_{aw} - t$)	17
3.2.2	La courbe de Débit-Temps ($Q - t$)	17
3.2.3	Corrélation des signaux pour Intelligence Artificielle	18
4	Ingénierie des données (Data Pipeline)	19
4.1	Génération et segmentation du Dataset simulé	19
4.1.1	L'avantage des données simulées	19
4.1.2	Filtrage et lissage du signal	20
4.1.3	Délimitation automatique des cycles respiratoires	20
4.2	Étiquetage (Labeling) et Préparation Tensorielle	20
4.2.1	Annotation automatisée via la pression musculaire (P_{mus})	20
4.2.2	Normalisation et mise en forme tensorielle	21
5	Conception de l'algorithme d'identification automatique des asynchronies	22
5.1	Choix de l'architecture : Le CNN-1D pour séries temporelles	22
5.1.1	Avantages par rapport aux réseaux récurrents	22
5.2	Anatomie du modèle CNNRespiratoire	23
5.2.1	Les couches de convolution (Feature Extraction)	23
5.2.2	Réduction de dimension et Sous-échantillonnage (Pooling)	23
5.2.3	La couche dense et la régularisation par Dropout	24
5.3	Stratégie d'entraînement et Optimisation	24
5.3.1	Fonction de perte : CrossEntropyLoss	24
5.3.2	Algorithme d'optimisation : Adam	24
5.3.3	Hardware et accélération CUDA	24
5.4	Analyse du processus d'apprentissage	24
6	Performances et validation de l'algorithme d'identification des APV	26
6.1	Métriques d'évaluation (Précision, Rappel, F1-Score)	26
6.1.1	Définitions mathématiques des métriques	27
6.1.2	Analyse des résultats par classe	27
6.2	Analyse de la Matrice de Confusion	27
6.2.1	Interprétation des résultats de la matrice	28
6.3	Interprétabilité des résultats (SHAP/LIME)	28
6.3.1	SHAP (SHapley Additive exPlanations)	28
6.3.2	LIME (Local Interpretable Model-agnostic Explanations)	29
6.3.3	Conclusion sur la validation du modèle	29
7	DISCUSSION ET PERSPECTIVES	30
7.1	Intégration sur moniteur de chevet	30
7.1.1	Architecture Matérielle : Le défi du "Edge Computing"	30
7.1.2	Optimisation Logicielle : Quantification et Pruning	31
7.1.3	Ergonomie et Interface Homme-Machine (IHM)	31
7.1.4	Sécurité, Cybersécurité et Normes Réglementaires	32

Conclusion générale	33
RÉFÉRENCES	35
ANNEXE A : SCRIPT PYTHON D'ENTRAÎNEMENT	37
ANNEXE B : LOGS D'EXÉCUTION DU TERMINAL	43

Table des figures

1.1	Configuration d'un bloc opératoire complet : équipements suspendus et table d'opération.	7
1.2	Installation active de respirateurs par les techniciens biomédicaux.	8
1.3	Poste de monitoring central : visualisation des scopes sur grands écrans.	8
3.1	Illustration d'une asynchronie de type double déclenchement (Double Triggering)	14
3.2	Illustration d'efforts inefficaces : contraction diaphragmatique non suivie d'une assistance mécanique.	15
3.3	Illustration d'un cyclage prématuré : le temps inspiratoire mécanique se termine avant la fin de l'effort neurologique du patient.	16
3.4	Illustration d'un cyclage tardif : l'assistance mécanique se prolonge au-delà de la fin de l'effort neurologique du patient.	16
4.1	Représentation graphique temporelle des données simulées illustrant le Débit, la Pression dans les voies aériennes (P_{aw}) et la Pression musculaire (P_{mus}).	20
5.1	Architecture détaillée du réseau de neurones convolutif 1D (CNN-1D) conçu pour l'analyse des cycles respiratoires (2 canaux en entrée, 3 classes en sortie).	23

Liste des tableaux

6.1	Rapport de classification généré par l'algorithme 1D-CNN sur l'ensemble de test.	27
6.2	Matrice de confusion du réseau CNNRespiratoire.	28

Liste des Sigles et Abréviations

1D-CNN	Convolutional Neural Network 1D (Réseau de Neurones Convolutif 1D)
AMDEC	Analyse des Modes de Défaillance, de leurs Effets et de leur Criticité
APV	Asynchronie Patient-Ventilateur
CHU	Centre Hospitalier Universitaire
IA	Intelligence Artificielle
ISSS	Institut Supérieur des Sciences de la Santé
EAdi	Electrical activity of the diaphragm index
PEP (PEEP)	Pression Expiratoire Positive
Pmus	Pression musculaire
SAV	Service Après-Vente
SCRIM	Société Commerciale de Représentation Industrielle et Médicale
VNI	Ventilation Non Invasive

INTRODUCTION GÉNÉRALE

- La ventilation mécanique est l'un des piliers de la prise en charge en unité de soins intensifs et en réanimation. Son objectif principal est de suppléer ou d'assister la fonction respiratoire défaillante du patient. Cependant, pour que cette assistance soit optimale, il est impératif que le ventilateur s'adapte parfaitement à la demande neurologique et mécanique du patient. Lorsque cette harmonie est rompue, on parle d'Asynchronies Patient-Ventilateur (APV).

La ventilation mécanique est un processus dynamique complexe où deux systèmes le patient et le ventilateur doivent interagir en temps réel. Cette interaction repose sur un dialogue permanent entre la commande neurale (le centre respiratoire du patient) et l'assistance mécanique délivrée par le respirateur. Le succès du sevrage ventilatoire dépend étroitement de la fluidité de cet échange. Toutefois, cette interaction est vulnérable ; elle est constamment perturbée par des facteurs cliniques variables (état de conscience, douleur, fièvre, ou instabilité hémodynamique).

Historiquement, et encore majoritairement aujourd'hui, l'identification de ces asynchronies repose sur l'analyse visuelle des courbes de monitoring affichées sur l'écran du respirateur (principalement les courbes de pression, de débit et de volume en fonction du temps). Bien que les cliniciens soient formés à reconnaître les anomalies typiques telles que les efforts inefficaces, les doubles déclenchements ou les retards de cyclage, cette méthode d'évaluation visuelle présente de nombreuses limites intrinsèques :

- **La subjectivité et l'expertise requise** : L'interprétation des formes d'ondes respiratoires nécessite un niveau d'expertise élevé. Des études montrent qu'une proportion significative d'asynchronies passe inaperçue, même auprès de professionnels expérimentés, car les altérations des courbes peuvent être subtiles ou noyées dans des artefacts (mouvements du patient, sécrétions, toux).
- **L'impossibilité d'une surveillance continue** : Un patient sous assistance respiratoire effectue en moyenne entre 15 000 et 25 000 cycles respiratoires par jour. Il est humainement impossible pour le personnel soignant de scruter l'écran du moniteur 24 heures sur 24. L'évaluation visuelle ne représente donc qu'un "instantané" (souvent de quelques minutes) de la situation du patient, ignorant totalement les épisodes asynchrones nocturnes ou survenant hors de la présence du médecin.
- **La charge cognitive et le manque de temps** : Dans un service de réanimation où la charge de travail est intense, analyser finement des courbes respiratoires cycle par cycle est extrêmement chronophage. Le temps médical est précieux et la détection manuelle des APV est souvent reléguée au second plan face aux urgences vitales immédiates.

Face à ce constat, le domaine biomédical opère une mutation technologique. L'émergence des techniques de *Deep Learning* et de l'analyse automatisée des signaux physiologiques (notamment l'activité électrique du diaphragme, ou *Eadi*) ouvre de nouvelles perspectives. Contrairement à l'il humain, ces outils sont capables d'analyser des flux de données massifs en continu, sans fatigue et avec une précision mathématique constante. L'automatisation ne vise pas à

remplacer le clinicien, mais à lui offrir un "oeil numérique" capable d'alerter en temps réel sur des dyssynchronies indétectables par des moyens classiques.

L'incapacité à détecter et corriger systématiquement ces asynchronies n'est pas sans conséquence. Les APV non résolues entraînent une augmentation significative du travail respiratoire, de l'inconfort, un besoin accru de sédation et, à terme, une fatigue des muscles respiratoires (notamment le diaphragme). Cela se traduit cliniquement par des durées de ventilation mécanique prolongées, un sevrage respiratoire plus difficile, et une augmentation globale de la morbidité et de la mortalité en réanimation.

Chapitre 1

Lieu de stage

1.1 Présentation de la Société Commerciale de Représentation Industrielle et Médicale (SCRIM)

1.1.1 Présentation de l'entreprise

La Société Commerciale de Représentation Industrielle et Médicale (SCRIM), basée à Casablanca, est un acteur majeur dans le domaine de la distribution, de l'installation et de la maintenance d'équipements médicaux et scientifiques au Maroc. Représentant des marques internationales de renommée, SCRIM joue un rôle d'intermédiaire privilégié entre les constructeurs mondiaux de dispositifs médicaux et les établissements de santé marocains (hôpitaux publics, CHU, cliniques privées et laboratoires).

L'entreprise s'engage non seulement à fournir des équipements de pointe (tels que les respirateurs artificiels, les générateurs d'hémodialyse, l'imagerie médicale et le monitoring), mais assure également un accompagnement complet allant de l'installation initiale à la maintenance, garantissant ainsi la pérennité des équipements et la sécurité des patients.

1.1.2 Organigramme de l'entreprise

Contrairement à la structure hospitalière, l'organisation de SCRIM est orientée vers la satisfaction client et la réactivité technique. Elle s'articule généralement autour de plusieurs pôles :

- **La Direction Générale** : Définit la stratégie et gère les partenariats avec les fournisseurs internationaux.
- **Le Service Commercial** : En charge de la réponse aux appels d'offres, de la vente et du conseil auprès des établissements de santé.
- **Le Service Technique et Biomédical (Service Après-Vente - SAV)** : Le cœur technique de l'entreprise, responsable de l'installation, de la mise en service, et de la maintenance (préventive et corrective) des équipements sur le terrain.
- **Le Service Logistique et Administratif** : Gère les stocks de pièces de rechange, les importations et l'administration des ventes.

1.1.3 Le Service Technique et Biomédical

Le service technique est le garant du bon fonctionnement des dispositifs médicaux vendus par SCRIM. Sous la supervision du responsable technique, Monsieur Fouad, et soutenu par une équipe de techniciens expérimentés tels que Messieurs Hamza et Mehdi, ce département est essentiel pour maintenir la confiance des clients.

Rôle et Missions du service

1. **Installation et mise en service** : Déploiement des nouveaux équipements au sein des blocs opératoires, des services de réanimation ou d'imagerie.
2. **Maintenance Préventive** : Réalisation des visites périodiques planifiées pour remplacer les pièces d'usure, calibrer les capteurs et garantir les performances d'origine des machines.
3. **Maintenance Corrective (Dépannage)** : Intervention rapide sur site ou en atelier suite à des signalements de panne pour minimiser le temps d'indisponibilité du matériel.
4. **Contrôle Qualité et Sécurité** : Vérification de la sécurité électrique et métrologique des appareils à l'aide de testeurs biomédicaux certifiés (analyseurs de débit, testeurs de sécurité électrique).

1.2 Bilan des Activités

Au terme de ce stage au sein de SCRIM, j'ai eu l'opportunité de m'immerger pleinement dans le rôle d'un spécialiste en instrumentation et maintenance biomédicale. Intégré au sein de l'équipe technique, j'ai pu lier mes connaissances théoriques acquises à l'ISSS à la réalité exigeante du terrain. Mes missions ont couvert l'ensemble du cycle de vie technique des dispositifs médicaux :

1.2.1 Installation et Mise en Service

J'ai participé activement à l'assemblage, au paramétrage et à la mise en service de divers équipements (notamment des dispositifs d'assistance respiratoire et de dialyse) au sein des établissements de santé. Cette étape implique le respect strict des protocoles d'installation dictés par les constructeurs et la réalisation de tests à blanc avant toute utilisation sur des patients.




FIGURE 1.1 : Configuration d'un bloc opératoire complet : équipements suspendus et table d'opération.



FIGURE 1.2 : Installation active de respirateurs par les techniciens biomédicaux.

1.2.2 Maintenance Préventive et Tests de Sécurité

La prévention étant primordiale dans le secteur médical, j'ai accompagné les techniciens lors des campagnes de maintenance. J'ai appris à utiliser des analyseurs biomédicaux pour vérifier la calibration des capteurs (pression, volume, débit) et à effectuer des tests de sécurité électrique (courants de fuite, résistance de terre) afin de prévenir tout risque de fibrillation ou d'électrisation.




FIGURE 1.3 : Poste de monitoring central : visualisation des scopes sur grands écrans.

1.2.3 Diagnostic et Maintenance Corrective

Face à des équipements en panne, j'ai été formé à la méthodologie de dépannage : analyse des codes d'erreur, lecture des schémas électroniques et pneumatiques, isolation de la carte ou du composant défectueux, et remplacement des pièces. Cette mission m'a permis de développer une grande capacité d'analyse et de résolution de problèmes complexes sous pression.

1.2.4 Formation des Utilisateurs et Traçabilité

Le travail biomédical ne se limite pas à la machine. J'ai assisté l'équipe lors des sessions de formation du personnel soignant pour garantir une utilisation optimale et sécurisée des équipements. De plus, j'ai pris part à la rédaction des fiches d'intervention et à la mise à jour de la base de données technique de l'entreprise, soulignant l'importance de la traçabilité documentaire pour le suivi de chaque dispositif médical.

1.2.5 Conclusion

Ce stage chez SCRIM a été une expérience profondément formatrice. Il m'a offert une vision globale du métier de biomédical dans le secteur privé et de la distribution. En travaillant aux côtés de Monsieur Fouad, Hamza et Mehdi, j'ai acquis des compétences pratiques pointues et compris que la rigueur, l'adaptabilité et la réactivité sont les piliers indispensables pour garantir la sécurité des soins à travers la fiabilité des équipements médicaux.

Chapitre 2

Automatisation par l'Intelligence Artificielle

Face aux limitations critiques de l'analyse visuelle humaine (charge cognitive, subjectivité, impossibilité de surveillance continue) détaillées dans notre problématique, il devient impératif de développer des outils capables d'assister les cliniciens. L'objectif est de surveiller, quantifier et classer les asynchronies patient-ventilateur (APV) de manière continue, objective et automatisée. C'est ici que l'Intelligence Artificielle (IA) intervient non pas comme un simple outil, mais comme une véritable solution de rupture technologique en ingénierie biomédicale.

2.1 Le Deep Learning comme solution de rupture

2.1.1 Limites des algorithmes déterministes classiques

Historiquement, les tentatives d'automatisation sur les respirateurs se sont basées sur des algorithmes déterministes classiques. Ces systèmes reposent sur des règles mathématiques strictes et des seuils fixes (par exemple : déclencher une alarme si la pression dépasse 30 cmH₂O ou si le volume courant chute en dessous d'un certain niveau).

Bien que faciles à implémenter, ces méthodes montrent rapidement leurs limites en réanimation. La physiologie d'un patient est dynamique et varie constamment sous l'effet de la sédation, de l'évolution de la pathologie ou de simples mouvements. Un seuil fixe génère invariablement un nombre massif de fausses alarmes (Faux Positifs). Cette sur-sollicitation sonore provoque ce que l'on appelle la "fatigue des alarmes" (Alarm Fatigue) chez le personnel soignant, conduisant parfois à la désactivation pure et simple des alertes, mettant ainsi la vie du patient en danger.

2.1.2 La pertinence de l'Apprentissage Profond (Deep Learning)

Contrairement aux approches classiques, l'apprentissage profond (Deep Learning) excelle dans la reconnaissance de motifs (Pattern Recognition) complexes et non linéaires au sein de grandes masses de données.

Plutôt que de vérifier si une valeur dépasse un seuil, un réseau de neurones artificiels analyse la "morphologie" et la "géométrie" globale de la courbe respiratoire, exactement comme le ferait l'il d'un médecin réanimateur expert. Le modèle apprend par lui-même, lors de sa phase d'entraînement, à identifier les caractéristiques subtiles d'une asynchronie (comme une légère encoche sur la courbe de débit ou une déformation de la courbe de pression), rendant la détection extrêmement robuste face aux bruits et aux artefacts physiologiques.

2.2 Démarche Technologique et Scientifique du Projet

L'objectif principal de ce mémoire est de concevoir et d'implémenter cet algorithme d'identification automatique. Pour mener à bien cette mission, le projet s'articule autour de trois grands piliers technologiques :

2.2.1 1. Extraction et traitement des signaux bruts

La matière première de notre intelligence artificielle est constituée des signaux physiologiques. Il s'agit de récupérer les données temporelles à haute fréquence (signaux de débit volumique et de pression dans les voies aériennes) directement depuis les capteurs du ventilateur. Cette phase inclut le prétraitement des données (Data Engineering) : nettoyage des bruits, filtrage, lissage des courbes et segmentation automatisée de la série temporelle continue en cycles respiratoires individuels. Sans une donnée d'entrée propre et bien formatée, le réseau de neurones ne peut pas converger correctement.

2.2.2 2. Exploitation des architectures Deep Learning

Le second pilier consiste à utiliser la puissance de calcul moderne pour concevoir le cerveau de notre système. En nous appuyant sur des bibliothèques informatiques open-source spécialisées (notamment le framework PyTorch), nous allons modéliser et entraîner un réseau de neurones. L'approche consistera à traiter les signaux respiratoires comme des séries temporelles (Time-Series). Nous adapterons des architectures mathématiques avancées, traditionnellement utilisées dans le traitement du signal ou la vision par ordinateur (comme les réseaux de neurones convolutifs 1D - CNN), pour extraire les caractéristiques cachées de chaque cycle respiratoire.

2.2.3 3. Classification et diagnostic en temps réel

L'aboutissement technologique est de générer un modèle prédictif capable de fonctionner en temps réel. Pour chaque souffle du patient (cycle analysé), l'algorithme devra déterminer avec une haute précision statistique (Accuracy, F1-Score) s'il s'agit d'un cycle normal et synchrone, ou s'il s'agit d'une anomalie. Le cas échéant, l'IA devra classer la sous-famille de l'asynchronie (double déclenchement, cyclage prématuré, effort inefficace, etc.), fournissant ainsi une information claire et exploitable.

2.3 Impacts et Bénéfices Cliniques Attendus

En automatisant cette détection via le Deep Learning, nous visons à faire évoluer la nature même du moniteur du respirateur : d'un simple afficheur passif de courbes brutes, il a vocation à devenir un véritable assistant diagnostique actif, ce que l'on nomme un **Système d'Aide à la Décision Clinique (CDSS - Clinical Decision Support System)**.

Les bénéfices attendus par l'implémentation d'une telle technologie sont majeurs et se déclinent à plusieurs niveaux :

2.3.1 Monitoring continu et Index d'Asynchronie

Le premier grand bénéfice est de fournir aux réanimateurs un **index d'asynchronie (AI)** calculé en continu sur 24 heures. Cet index, défini comme le pourcentage d'événements asynchrones par rapport au nombre total de cycles respiratoires, permet d'objectiver mathématiquement la qualité de l'interaction patient-machine. Le médecin n'a plus besoin de deviner ce qui s'est passé durant la nuit ; il dispose d'un rapport détaillé et d'une courbe de tendance claire.

2.3.2 Réduction de la charge cognitive des équipes

En filtrant intelligemment les informations et en ne remontant que les alertes pertinentes (haut niveau de confiance du réseau de neurones), le système réduit drastiquement la charge cognitive des équipes soignantes. Cela permet aux infirmiers et médecins de se concentrer sur des tâches à plus forte valeur ajoutée humaine et médicale, tout en diminuant le stress lié à la pollution sonore des fausses alarmes dans le service.

2.3.3 Personnalisation du traitement et amélioration du pronostic

Enfin, sur le plan strictement thérapeutique, une détection précoce permet un ajustement immédiat et ciblé des paramètres ventilatoires (réglage de la PEEP, sensibilité du Trigger, ajustement du temps inspiratoire). Une machine parfaitement synchronisée favorise le confort du patient, réduit la nécessité de recourir à des sédatifs lourds, protège le diaphragme de l'épuisement et permet, *in fine*, un sevrage plus rapide de la ventilation mécanique.

En conclusion de ce chapitre, ce projet d'ingénierie biomédicale se positionne à la convergence exacte de l'instrumentation médicale matérielle et de la science des données (Data Science). En proposant de transformer un signal brut en une information diagnostique de haute précision, il répond à un besoin hospitalier critique avec pour finalité directe la sécurité du patient et l'amélioration de la qualité des soins en réanimation.

Chapitre 3

État de l’art des Asynchronies Patient-Ventilateur

L’interaction entre un patient et un ventilateur mécanique repose sur un équilibre fragile. Pour comprendre comment une intelligence artificielle peut identifier les défauts de cette interaction, il est indispensable de maîtriser la physiopathologie des asynchronies et la morphologie des signaux générés par les capteurs du respirateur. Ce chapitre dresse l’état de l’art des anomalies respiratoires et détaille l’analyse des signaux ventilatoires.

3.1 Caractérisation des asynchronies

Une asynchronie patient-ventilateur (APV) survient lorsqu’il y a un décalage temporel ou quantitatif entre la commande respiratoire neurale du patient (ce que son cerveau demande) et l’assistance pneumatique délivrée par la machine (ce que le ventilateur fournit). Pour concevoir un modèle d’Intelligence Artificielle robuste, il est crucial de classifier de manière exhaustive les différents types d’APV qui peuvent se superposer dans les données.

3.1.1 Le Double Déclenchement (Double Triggering)

Le double déclenchement est l’une des asynchronies les plus délétères pour les poumons du patient. Il se produit lorsque le temps inspiratoire neuronal du patient est significativement plus long que le temps inspiratoire mécanique réglé sur le ventilateur.




FIGURE 3.1 : Illustration d'une asynchronie de type double déclenchement (Double Triggering)

Mécanisme : Le ventilateur termine son cycle inspiratoire et ouvre la valve expiratoire, mais le patient continue de faire un effort inspiratoire (contraction diaphragmatique). Si cet effort est suffisant, il va "déclencher" (trigger) un deuxième cycle mécanique consécutif avant même que l'expiration du premier cycle n'ait pu avoir lieu.

Conséquences cliniques :

- **Volutrauma et Barotrauma :** Le volume courant du second cycle s'ajoute au volume non expiré du premier, entraînant une surdistension alvéolaire massive (le volume empilé peut atteindre le double du volume consigné).
- **Inconfort majeur :** Cette asynchronie provoque une sensation d'étouffement chez le patient, augmentant l'anxiété et la consommation d'oxygène.

3.1.2 L'Effort Inefficace (Ineffective Effort)

C'est l'une des asynchronies les plus fréquentes en réanimation. Elle se produit lorsque le patient initie une contraction musculaire inspiratoire, mais que la machine ne délivre aucun cycle.




FIGURE 3.2 : Illustration d'efforts inefficaces : contraction diaphragmatique non suivie d'une assistance mécanique.

Mécanisme : Le patient tente d'inspirer, mais son effort est trop faible pour vaincre le seuil de déclenchement (trigger) du respirateur. Cela est souvent causé par une faiblesse musculaire du diaphragme, un niveau de sédation trop profond, ou surtout par la présence d'une Auto-PEEP (Pression Expiratoire Positive intrinsèque liée à un piégeage d'air dans les poumons). Le patient doit alors vaincre cette pression supplémentaire avant même d'atteindre le seuil du ventilateur.

3.1.3 Les anomalies de cyclage (Prématuré et Tardif)

Le cyclage définit le moment où le ventilateur décide de terminer l'inspiration pour passer à la phase expiratoire.

- **Le cyclage prématuré (Premature Cycling) :** Le ventilateur arrête son assistance mécanique (fin de l'inspiration) alors que l'effort neural du patient est encore actif. Cela crée un besoin d'air insatisfait (frustration inspiratoire). Le patient continue de "tirer" pendant la phase expiratoire de la machine.




FIGURE 3.3 : Illustration d'un cyclage prématuré : le temps inspiratoire mécanique se termine avant la fin de l'effort neurologique du patient.

- **Le cyclage tardif (Delayed Cycling) :** À l'inverse, la machine continue de pousser de l'air alors que l'effort inspiratoire du patient est terminé et qu'il souhaite expirer. Le patient se retrouve à devoir forcer l'expiration contre une machine qui insuffle encore de l'air (freinage expiratoire), générant un travail respiratoire intense et un inconfort.




FIGURE 3.4 : Illustration d'un cyclage tardif : l'assistance mécanique se prolonge au-delà de la fin de l'effort neurologique du patient.

3.1.4 L'asynchronie de flux (Flow Starvation / Inadequate Flow)

Cette asynchronie n'est pas un problème de synchronisation temporelle (début/fin du cycle), mais un problème de débit.

Mécanisme : La machine délivre un débit d'air fixe ou insuffisant par rapport à l'appel inspiratoire du patient. Le patient "tire" plus fort que ce que la machine ne donne. Il en résulte un travail additionnel des muscles respiratoires accessoires pour tenter d'obtenir le débit manquant, causant une fatigue respiratoire rapide.

3.1.5 Les Fuites (Leaks) et l'Auto-déclenchement

Bien que les fuites soient techniquement un problème d'étanchéité mécanique plutôt qu'une anomalie neurologique, elles perturbent dramatiquement la synchronisation en trompant les capteurs du respirateur. Elles surviennent fréquemment en Ventilation Non Invasive (VNI) au niveau du masque, ou en ventilation invasive au niveau du ballonnet de la sonde d'intubation ou du circuit patient.

L'Auto-déclenchement (Auto-triggering) : C'est la conséquence la plus directe d'une fuite importante ou de la présence d'eau dans le circuit patient. En mode déclenchement en débit (Flow Trigger), le ventilateur interprète une baisse du débit de base due à une fuite (ou à une oscillation) comme un effort inspiratoire du patient. La machine va alors insuffler un cycle sans qu'aucune demande physiologique ne l'ait initié. Si la fuite est continue, cela peut générer une hyperventilation artificielle et une alcalose respiratoire.

3.2 Analyse du signal ventilatoire (Débit/Pression)

Pour le technicien biomédical comme pour l'algorithme de Deep Learning, la détection de ces asynchronies repose sur l'analyse fine des séries temporelles acquises à haute fréquence par les pneumotachographes et les capteurs de pression du respirateur.

3.2.1 La courbe de Pression-Temps ($P_{aw} - t$)

Ce signal représente la pression dans les voies aériennes au cours du temps. En fonctionnement normal, la courbe débute à la valeur de la Pression Expiratoire Positive (PEP). Lors de l'inspiration, la pression monte jusqu'à une Pression de Crête (PIP), puis redescend à la PEP lors de l'expiration.

Signature visuelle des anomalies sur la pression :

- **En cas d'effort inefficace :** On observe une légère déflexion négative (creux) sur le plateau expiratoire de la courbe de pression, signe que le patient "tire" sur un circuit fermé sans déclencher de cycle.
- **En cas d'asynchronie de flux (Flow starvation) :** La courbe de pression, au lieu d'avoir un aspect convexe ou plat pendant l'insufflation, se creuse et prend un aspect concave (en forme de cuillère). Le patient demande plus de débit que ce que la machine fournit, créant une dépression relative dans le circuit.

3.2.2 La courbe de Débit-Temps ($Q - t$)

C'est le signal le plus riche en informations dynamiques. L'inspiration est représentée par une aire positive (débit entrant) et l'expiration par une aire négative (débit sortant).

Détection des Fuites sur le débit : Une fuite se lit instantanément sur cette courbe. En temps normal, le débit expiratoire doit revenir exactement à zéro avant le début du cycle

suivant. S'il y a une fuite, la courbe expiratoire s'aplatit et ne rejoint jamais la ligne de base (le zéro). L'écart entre la ligne de base et la fin de l'expiration représente le volume de fuite continu.

Détection du Double Déclenchement sur le débit : Sur la courbe de débit, le double déclenchement se caractérise par deux pics inspiratoires (positifs) consécutifs, séparés par un temps expiratoire (débit négatif) extrêmement bref, voire inexistant. Le volume n'ayant pas eu le temps de sortir, la courbe passe directement d'un débit positif à un autre débit positif.

3.2.3 Corrélation des signaux pour Intelligence Artificielle

L'analyse isolée d'un seul signal est souvent insuffisante pour poser un diagnostic de certitude. Par exemple, une encoche sur le débit expiratoire peut être un effort inefficace ou simplement le résultat de sécrétions dans les tuyaux (bruit). C'est la corrélation simultanée des perturbations sur la courbe de débit et sur la courbe de pression qui confirme l'asynchronie.

C'est précisément cette analyse multivariée temporelle qui justifie l'utilisation du Deep Learning. Les réseaux de neurones (que nous aborderons dans les chapitres suivants) sont capables de traiter ces deux canaux de données simultanément (P_{aw} et Q), d'extraire des caractéristiques géométriques subtiles invisibles à l'oeil nu, et de généraliser ces motifs pour classifier chaque cycle avec précision. Les signaux bruts de débit et de pression constituent ainsi la matière première (le Dataset) indispensable à l'entraînement de notre modèle d'intelligence artificielle.

Chapitre 4

Ingénierie des données (Data Pipeline)

La performance d'un modèle d'intelligence artificielle repose fondamentalement sur la qualité et la structuration des données qui le nourrissent. Avant même d'envisager l'entraînement d'un réseau de neurones, il est impératif de construire un "pipeline" de données robuste. Ce chapitre détaille les étapes de traitement informatique développées en Python (via les bibliothèques Pandas et NumPy) pour transformer nos jeux de données en un format mathématique exploitable par l'IA.

4.1 Génération et segmentation du Dataset simulé

4.1.1 L'avantage des données simulées

Les données initiales se présentent sous la forme de multiples fichiers `.csv` contenant des enregistrements à haute fréquence des paramètres ventilatoires (débit, pression dans les voies aériennes, pression musculaire).

Contrairement à des données cliniques acquises directement sur un respirateur de réanimation, notre Dataset est constitué de données simulées. Ce choix méthodologique est stratégique : en clinique, l'évaluation précise de l'effort neural du patient nécessite la pose invasive d'un ballonnet oesophagien pour mesurer la pression musculaire (P_{mus}). Grâce à la simulation mathématique et physiologique, nous disposons nativement d'une courbe de P_{mus} parfaite et continue.

La première étape de notre script parcourt automatiquement le répertoire de fichiers simulés. Une vérification d'intégrité est effectuée : les fichiers de simulation ne contenant pas la variable P_{mus} (tels que *Run622.csv* à *Run630.csv*) sont systématiquement ignorés, car cette variable constitue notre repère absolu pour l'étiquetage.




FIGURE 4.1 : Représentation graphique temporelle des données simulées illustrant le Débit, la Pression dans les voies aériennes (P_{aw}) et la Pression musculaire (P_{mus}).

4.1.2 Filtrage et lissage du signal

Même dans un environnement simulé, le traitement numérique requiert une préparation des courbes pour garantir une détection algorithmique sans faille du début et de la fin de chaque respiration. Un lissage mathématique est appliqué au signal de débit (**flow**). Nous avons utilisé une méthode de moyenne mobile centrée (*rolling mean*) sur une fenêtre de 5 échantillons. Cette technique permet de lisser la courbe et d'éliminer les éventuelles variations numériques brusques sans altérer la morphologie globale du cycle respiratoire.

4.1.3 Délimitation automatique des cycles respiratoires

Une fois le signal de débit lissé, l'algorithme procède à la segmentation de la série temporelle continue en cycles individuels. La méthode repose sur la détection du passage à zéro (Zero-crossing) de la courbe de débit. Un cycle démarre lorsque le débit devient positif (début de l'inspiration) et se termine au passage positif suivant. Pour éliminer les micro-segments générés par des oscillations numériques autour du zéro, un filtre de longueur a été implémenté : tout segment comportant moins de 50 points de données est rejeté. Cette extraction nous a permis d'isoler un total massif de **63 857 cycles respiratoires** exploitables.

4.2 Étiquetage (Labeling) et Préparation Tensorielle

4.2.1 Annotation automatisée via la pression musculaire (P_{mus})

L'apprentissage supervisé nécessite que chaque cycle soit accompagné d'une "étiquette" (Label) indiquant s'il est normal ou asynchrone. L'annotation manuelle de près de 64 000 cycles étant impossible, nous avons développé une fonction de labellisation automatique exploitant notre fameuse variable de simulation P_{mus} .

La logique algorithmique compare le temps de cyclage mécanique (défini par le passage du débit en phase expiratoire, c'est-à-dire négative) avec la fin de l'effort neural simulé du patient.

Un effort neural significatif est validé lorsque la P_{mus} franchit un seuil de détection strict fixé à -1.0 cmH₂O. L’algorithme calcule l’écart de temps (Δt) entre la fin de l’insufflation mécanique et la fin de l’effort neural, en appliquant une tolérance de 0.1 seconde (**TOLERANCE_TIME**) :

- **Cycle Normal (None)** : Le décalage est compris dans la zone de tolérance ($-0.1 \text{ s} \leq \Delta t \leq 0.1 \text{ s}$). Le patient simulé et le ventilateur virtuel sont synchronisés.
- **Cyclage Prématuro (Premature)** : La fin de l’assistance mécanique survient trop tôt par rapport à l’effort prolongé du patient ($\Delta t < -0.1 \text{ s}$).
- **Cyclage Retardé (Delayed)** : L’assistance mécanique se prolonge inutilement alors que le patient a terminé son inspiration ($\Delta t > 0.1 \text{ s}$).

4.2.2 Normalisation et mise en forme tensorielle

Les réseaux de neurones exigent des tenseurs (matrices de données) de dimensions strictement identiques en entrée. Or, la durée d’un cycle respiratoire est par nature variable, même en simulation.

Pour uniformiser les données, la classe **AsynchronyDataset** a été développée en PyTorch. Elle impose une longueur maximale de 500 échantillons temporels par cycle (**max_len** = 500) :

- Les cycles plus longs sont **tronqués** à 500 points.
- Les cycles plus courts subissent un **Padding** (remplissage avec des zéros) jusqu’à atteindre la taille requise.

Enfin, seules les variables cliniquement exploitables par le futur réseau (le débit **flow** et la pression **paw**) sont conservées et transposées sous la forme de tenseurs (**Canaux**, **Temps**), générant pour chaque cycle une matrice de taille 2×500 .

Ce format standardisé constitue l’aboutissement du Pipeline. Le jeu de données global de 63 857 cycles est alors divisé de manière stratifiée (pour préserver la proportion des classes) : **80% pour l’entraînement (soit 51 085 cycles)** afin de faire converger le modèle, et **20% pour le test (soit 12 772 cycles)** pour valider ses performances sur des données inédites. Les tenseurs sont désormais prêts à être injectés dans l’architecture Deep Learning.

Chapitre 5

Conception de l'algorithme d'identification automatique des asynchronies

L'objectif central de ce projet est de s'affranchir des règles de détection rigides et manuelles pour passer à une approche apprenante. Ce chapitre détaille la conception, l'architecture et la stratégie d'entraînement du modèle d'intelligence artificielle développé. Nous justifierons le choix d'une architecture convolutive unidimensionnelle (1D-CNN) et expliquerons mathématiquement comment le modèle apprend à identifier les asynchronies à partir des signaux de pression et de débit simulés.

5.1 Choix de l'architecture : Le CNN-1D pour séries temporelles

Historiquement, le traitement des séquences temporelles était réservé aux réseaux récurrents (LSTM ou GRU). Cependant, dans le cadre de l'instrumentation biomédicale et du traitement du signal respiratoire, nous avons opté pour une approche par **Convolution Unidimensionnelle (1D-CNN)**.

5.1.1 Avantages par rapport aux réseaux récurrents

Contrairement aux réseaux récurrents qui traitent les données point par point (ce qui est lent et sujet à la disparition du gradient), le CNN-1D traite le signal par "fenêtres" glissantes. Les avantages pour notre projet sont triples :

- **Extraction de caractéristiques locales** : Le CNN est capable de détecter des motifs géométriques précis (comme une encoche sur la pression ou une cassure du débit) indépendamment de leur position exacte dans le cycle.
- **Efficacité computationnelle** : Comme le montre notre terminal, l'utilisation de la technologie CUDA sur GPU permet un calcul parallèle massif. Le CNN est naturellement adapté à cette accélération, rendant l'entraînement beaucoup plus rapide.
- **Invariance spatiale** : Que l'asynchronie survienne au début ou à la fin de l'inspiration, les filtres convolutifs sauront extraire la même signature morphologique.

5.2 Anatomie du modèle CNNRespiratoire

L'architecture que nous avons implémentée dans le script se nomme **CNNRespiratoire**. Elle est structurée en trois blocs de traitement successifs (Extraction de caractéristiques) suivis d'un bloc de classification (Couches denses).




FIGURE 5.1 : Architecture détaillée du réseau de neurones convolutif 1D (CNN-1D) conçu pour l'analyse des cycles respiratoires (2 canaux en entrée, 3 classes en sortie).

5.2.1 Les couches de convolution (Feature Extraction)

Comme illustré sur la figure ci-dessus, le modèle reçoit en entrée un tenseur de dimension (2, 500), correspondant aux deux canaux (*Flow* et *Paw*) sur 500 points de temps.

- **Bloc 1 (Conv1D_1) :** 16 filtres de taille 5. Ce premier étage "scanne" le signal pour détecter des motifs de base (pentes, pics).
- **Bloc 2 (Conv1D_2) :** 32 filtres de taille 5. Ce niveau combine les motifs de base pour identifier des formes plus complexes (début d'effort, fin d'insufflation).
- **Bloc 3 (Conv1D_3) :** 64 filtres de taille 3. Ce dernier étage extrait des caractéristiques de haut niveau, prêtes pour la décision finale.

Chaque couche utilise la fonction d'activation **ReLU** (Rectified Linear Unit), définie par $f(x) = \max(0, x)$, qui permet d'introduire la non-linéarité nécessaire à la compréhension de phénomènes physiologiques complexes.

5.2.2 Réduction de dimension et Sous-échantillonnage (Pooling)

Après chaque convolution, nous avons intégré une couche de **MaxPool1D** de taille 2. Le rôle de cette opération est de diviser par deux la résolution temporelle en ne conservant que la valeur maximale de chaque fenêtre. Cela permet non seulement de réduire le nombre de calculs (évitant ainsi le sur-apprentissage), mais aussi de rendre le modèle plus robuste aux petits bruits de signal. À la fin de ces étapes, nos 500 points initiaux sont condensés en 62 vecteurs de caractéristiques de profondeur 64.

5.2.3 La couche dense et la régularisation par Dropout

Une fois les caractéristiques extraites, les données passent dans le bloc de classification entièrement connecté (*Fully Connected Layers*) :

- **Aplatissement (Flattening)** : Les matrices multidimensionnelles sont transformées en un vecteur unique de 3 968 neurones (64×62).
- **Couche Cachée (FC1)** : Un étage de 128 neurones effectue la synthèse finale des informations.
- **Le Dropout (0.5)** : C'est une technique de régularisation cruciale. Durant l'entraînement, 50% des neurones sont désactivés aléatoirement. Cela force le réseau à ne pas dépendre d'un seul chemin de décision et garantit que l'IA pourra généraliser ses connaissances.
- **Sortie (FC2)** : Une couche finale de 3 neurones correspondant à nos probabilités de prédiction : Normal (None), Premature, ou Delayed.

5.3 Stratégie d'entraînement et Optimisation

5.3.1 Fonction de perte : CrossEntropyLoss

Le modèle est entraîné pour minimiser une "fonction de coût". Puisqu'il s'agit d'une classification multiclasse, nous utilisons la **Cross-Entropy**. Mathématiquement, elle mesure l'écart entre la probabilité prédite par l'IA et la classe réelle issue de notre simulation. Plus l'erreur est faible, plus le modèle est "confiant" dans son diagnostic.

5.3.2 Algorithme d'optimisation : Adam

Pour mettre à jour les poids du réseau, nous utilisons l'optimiseur **Adam** avec un taux d'apprentissage (*learning rate*) de 0.001. Adam est une méthode de descente de gradient stochastique qui ajuste automatiquement le pas d'apprentissage pour chaque paramètre, permettant une convergence plus stable et rapide vers la solution optimale.

5.3.3 Hardware et accélération CUDA

Le développement a été réalisé en utilisant l'interface PyTorch `torch.device("cuda")`. Comme indiqué dans notre terminal de sortie, l'appareil utilisé est un processeur graphique (GPU) compatible **NVIDIA CUDA**. Cela permet d'effectuer les multiplications matricielles du CNN de manière hautement parallélisée, rendant possible l'entraînement sur 51 085 cycles en un temps réduit.

5.4 Analyse du processus d'apprentissage

L'entraînement s'est déroulé sur **10 époques**. Une époque correspond à un passage complet du modèle sur l'ensemble des données d'entraînement.

Comme le montre notre historique d'exécution :

- **Époque 1** : L'erreur (*Loss*) initiale est de 0.4225. Le modèle commence à peine à ajuster ses poids.
- **Convergence** : On observe une chute régulière et rapide de la perte. Dès l'époque 3, l'erreur descend sous la barre des 0.20.
- **Époque 10** : Le modèle stabilise son erreur à 0.1255. Cette stabilité indique que l'apprentissage est arrivé à maturité et que le réseau a extrait le maximum d'informations

pertinentes du Dataset simulé sans entrer dans une phase de mémorisation excessive (*overfitting*).

Le modèle est alors prêt pour l'étape de validation : l'évaluation sur les 12 772 cycles de test que le réseau n'a pas vus durant l'entraînement. Les performances statistiques de cette prédiction seront détaillées dans le chapitre suivant.

Chapitre 6

Performances et validation de l'algorithme d'identification des APV

Introduction

À l'issue de la phase de conception et d'entraînement détaillée dans le chapitre précédent, notre modèle de réseau de neurones convolutif unidimensionnel (1D-CNN) a été soumis à une évaluation rigoureuse. L'objectif de ce chapitre est de quantifier, d'analyser et d'interpréter les performances de l'algorithme sur des données inédites qu'il n'a jamais rencontrées durant sa phase d'apprentissage.

Le pipeline de données a permis d'extraire un total massif de 63 857 cycles respiratoires exploitables à partir des fichiers de simulation. Après une séparation stratifiée, l'entraînement s'est déroulé de manière optimale sur 10 époques. L'historique d'exécution montre une convergence excellente de la fonction de perte (Cross-Entropy Loss), débutant à 0.4354 à la première époque pour se stabiliser à 0.1173 à la dixième époque. Cette stabilité prouve que le modèle a su extraire les motifs géométriques des signaux de pression et de débit sans sombrer dans le sur-apprentissage.

Nous analyserons dans un premier temps les métriques d'évaluation globales, puis nous détaillerons les résultats à travers la matrice de confusion, avant de discuter des perspectives d'interprétabilité du modèle (SHAP et LIME), essentielles pour une intégration clinique réussie.

6.1 Métriques d'évaluation (Précision, Rappel, F1-Score)

Pour évaluer un modèle de classification médicale, l'exactitude globale (Accuracy) ne suffit pas, particulièrement lorsque les classes sont déséquilibrées. Il est impératif de décomposer la performance de l'algorithme à travers des métriques statistiques avancées.

Lors de l'évaluation sur l'ensemble de test (12 772 cycles respiratoires), le rapport de classification a mis en évidence une performance globale exceptionnelle avec une **exactitude (Accuracy) de 96%**.

Il est important de noter une particularité liée à la constitution du jeu de données final : bien que l'architecture du réseau ait été conçue pour prédire 3 classes (Normal, Premature, Delayed), l'application d'un seuil strict de détection de l'effort neural ($P_{mus} \leq -1.0 \text{ cmH}_2\text{O}$) et d'une fenêtre de tolérance temporelle de 0.1 seconde a filtré les asynchronies de type "Delayed" dans le sous-ensemble de test. L'évaluation s'est donc concentrée sur la distinction binaire cruciale entre les cycles synchrones ("None") et les cyclages prématurés ("Premature").

6.1.1 Définitions mathématiques des métriques

Les métriques reposent sur quatre composantes fondamentales issues des prédictions :

- **Vrais Positifs (VP)** : L'IA prédit correctement une asynchronie.
- **Vrais Négatifs (VN)** : L'IA prédit correctement un cycle normal.
- **Faux Positifs (FP)** : L'IA détecte une asynchronie à tort (fausse alarme).
- **Faux Négatifs (FN)** : L'IA manque une asynchronie réelle (sous-diagnostic).

À partir de ces valeurs, nous calculons les métriques suivantes :

1. La Précision (Precision) : Elle mesure la fiabilité de l'alarme déclenchée par l'algorithme.

$$Precision = \frac{VP}{VP + FP}$$

2. Le Rappel ou Sensibilité (Recall) : Il évalue la capacité du modèle à détecter toutes les anomalies existantes sans en oublier.

$$Recall = \frac{VP}{VP + FN}$$

3. Le F1-Score : C'est la moyenne harmonique entre la précision et le rappel. Il offre une vision équilibrée de la performance.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

6.1.2 Analyse des résultats par classe

Les résultats issus du terminal lors de la phase de test révèlent les performances suivantes :

Classe	Précision	Rappel (Recall)	F1-Score	Support (Nombre de cycles)
None (Normal)	0.97	0.98	0.97	9220
Premature	0.94	0.92	0.93	3552
<i>Moyenne macro</i>	0.95	0.95	0.95	12772
<i>Moyenne pondérée</i>	0.96	0.96	0.96	12772

TABLE 6.1 : Rapport de classification généré par l'algorithme 1D-CNN sur l'ensemble de test.

Pour la classe "None" (Cycles normaux) :

Avec un support majoritaire de 9220 cycles, l'algorithme démontre une maîtrise quasi parfaite de la physiologie normale. Le rappel de 98% indique que la quasi-totalité des respirations saines est correctement laissée tranquille par l'algorithme, évitant ainsi de polluer l'environnement de réanimation par de fausses alertes.

Pour la classe "Premature" (Cyclage prématuré) :

Détecter un cyclage prématuré est un défi, car la fin de l'assistance mécanique survient trop tôt par rapport à l'effort prolongé du patient, générant de subtiles variations sur les courbes de débit et de pression. Notre 1D-CNN atteint une précision de 94% et un rappel de 92%. Ce F1-score de 0.93 est remarquable : il signifie que l'IA identifie avec une très haute fiabilité cette frustration inspiratoire, surpassant largement les capacités de l'analyse visuelle humaine continue.

6.2 Analyse de la Matrice de Confusion

La matrice de confusion est l'outil visuel et analytique par excellence pour comprendre la nature exacte des erreurs commises par le réseau de neurones. Contrairement aux métriques globales, elle permet de voir précisément quelles classes sont confondues entre elles.

6.2.1 Interprétation des résultats de la matrice

La matrice de confusion obtenue lors du test sur nos 12 772 cycles s'établit ainsi :

Vérité Terrain \ Prédictions de l'IA	None	Premature
None	9002 (VN)	218 (FP)
Premature	290 (FN)	3262 (VP)

TABLE 6.2 : Matrice de confusion du réseau CNNRespiratoire.

Analyse des diagonales (Les succès) : La diagonale principale regroupe les prédictions correctes. L'algorithme a classé de manière irréprochable 9002 cycles normaux et 3262 asynchronies prématurées. Cela démontre que les couches de convolution (notamment les 64 filtres du dernier bloc d'extraction) ont parfaitement synthétisé les caractéristiques morphologiques des signaux respiratoires.

Analyse des Faux Positifs (218 cycles) : Dans 218 cas, le modèle a signalé une asynchronie "Premature" alors que la simulation étiquetait le cycle comme normal. Cliniquement, ces erreurs "par excès" sont souvent liées à de micro-artefacts sur la courbe de débit, simulant un appel inspiratoire résiduel. En réanimation, un faux positif algorithmique est généralement moins délétère qu'un faux négatif, bien qu'une accumulation excessive puisse causer une "fatigue des alarmes" chez le personnel soignant. Toutefois, 218 erreurs sur 9220 cycles sains représentent un taux d'erreur négligeable de 2.3%.

Analyse des Faux Négatifs (290 cycles) : L'algorithme a manqué 290 asynchronies prématurées, les considérant comme normales. Ces cas correspondent très probablement à des efforts neuraux "à la limite" de notre seuil de tolérance de 0.1 seconde. L'effort du patient dépassant de très peu la fin de l'insufflation, la modification géométrique de la courbe P_{aw} n'était pas assez discriminante pour être captée par le MaxPool1D. L'impact de ce sous-diagnostic de 8% (290/3552) reste cliniquement tout à fait acceptable comparé au sous-diagnostic humain qui, selon la littérature, ignore la majorité de ces événements asynchrones.

6.3 Interprétabilité des résultats (SHAP/LIME)

L'un des défis majeurs dans le déploiement de l'Intelligence Artificielle en instrumentation biomédicale réside dans l'effet "boîte noire" (Black Box) des algorithmes de Deep Learning. Si notre modèle 1D-CNN affiche une exactitude de 96%, il ne justifie pas "pourquoi" il a pris sa décision.

Pour qu'un tel outil soit accepté par les médecins réanimateurs et les techniciens biomédicaux chargés de la maintenance des respirateurs, il doit être transparent et explicable. C'est ici qu'interviennent les méthodes d'Intelligence Artificielle Explicable (XAI), notamment SHAP et LIME.

6.3.1 SHAP (SHapley Additive exPlanations)

La méthode SHAP est issue de la théorie des jeux coopératifs. Elle permet de quantifier la contribution marginale de chaque variable d'entrée (ici, les points spécifiques sur la courbe de pression et de débit) à la prédiction finale du modèle.

Dans le contexte de notre analyse des signaux P_{aw} et Q sur 500 pas de temps :

- **L'approche théorique :** SHAP calcule une valeur pour chaque point du signal temporel. Une valeur SHAP positive pousse la prédiction vers la classe asynchrone ("Premature"), tandis qu'une valeur négative la maintient dans la classe "Normal".

- **Pertinence clinique :** En appliquant SHAP à notre modèle CNNRespiratoire, il serait possible de superposer une "carte de chaleur" (Heatmap) directement sur les courbes du respirateur. Par exemple, si l'IA détecte un double déclenchement, SHAP surlignera en rouge l'absence d'expiration complète (débit restant positif). Pour le cyclage prématuré, SHAP mettrait en évidence la cassure spécifique sur la courbe de débit en fin d'insufflation.

6.3.2 LIME (Local Interpretable Model-agnostic Explanations)

LIME adopte une approche différente en créant un "modèle de substitution local". Plutôt que de tenter d'expliquer l'intégralité des 3968 neurones interconnectés, LIME explique une prédiction individuelle (un cycle respiratoire spécifique).

- **Le mécanisme de LIME sur les séries temporelles :** L'algorithme va légèrement perturber (bruitage artificiel ou masquage de segments) le cycle respiratoire testé et observer comment le CNN réagit. Si le masquage du dernier quart de la courbe de pression fait chuter la probabilité de "Premature" de 95% à 10%, LIME conclut que ce segment était le déclencheur de la décision.
- **Bénéfice direct pour le Système d'Aide à la Décision :** Couplé à notre système, LIME permettrait de fournir au réanimateur un message clair, tel que : *"Asynchronie détectée avec 94% de confiance, car l'anomalie se situe entre la milliseconde 300 et 450 sur le canal du débit"*.

6.3.3 Conclusion sur la validation du modèle

Les performances obtenues au cours de ce chapitre valident brillamment l'hypothèse de départ de notre projet de fin d'études : le Deep Learning est capable de pallier les limites de la détection visuelle humaine. Avec des métriques supérieures à 95% et un pipeline de traitement de données (Data Pipeline) robuste, l'algorithme a prouvé son efficacité.

L'intégration future d'outils d'interprétabilité comme SHAP et LIME constituera la dernière étape pour transformer ce réseau de neurones performant en un véritable assistant biomédical digne de , garantissant une ventilation mécanique protectrice, personnalisée et sécurisée pour les patients en soins intensifs.

Chapitre 7

DISCUSSION ET PERSPECTIVES

Introduction

L'élaboration de ce projet de fin d'études nous a conduits à explorer l'intersection prometteuse entre l'instrumentation biomédicale traditionnelle et les sciences de l'intelligence artificielle. Les résultats obtenus lors de la phase de test, avec une exactitude de 96% dans la détection du cyclage prématuré via un réseau de neurones convolutif (1D-CNN), démontrent sans ambiguïté la viabilité technique de notre approche. L'algorithme a prouvé sa capacité à pallier les limites inhérentes à la détection visuelle humaine, souvent entravée par la charge cognitive, la fatigue et la subtilité des altérations morphologiques sur les courbes respiratoires.

Cependant, un algorithme performant sur une station de travail dotée de puissantes capacités de calcul (GPU) ne constitue que la première étape d'un long processus d'ingénierie. Pour que cette innovation quitte l'environnement de développement et trouve sa place au chevet du patient en unité de soins intensifs, elle doit surmonter de multiples défis technologiques, ergonomiques et réglementaires.

Ce dernier chapitre s'articule autour de deux axes majeurs. Dans un premier temps, nous discuterons en profondeur des perspectives d'intégration de notre modèle d'IA directement sur les moniteurs de chevet ou au sein même de l'architecture matérielle des respirateurs. Dans un second temps, nous dresserons un bilan exhaustif de ce travail, tant sur le plan scientifique que sur le plan de l'évolution professionnelle, en concluant sur les horizons ouverts par cette recherche.

7.1 Intégration sur moniteur de chevet

L'objectif ultime de notre algorithme est de fonctionner en temps réel, 24 heures sur 24, sans nécessiter l'intervention constante d'un technicien ou d'un médecin. Cette transition vers le "Temps Réel" (Real-Time Monitoring) implique la conception d'un Système Embarqué (Embedded System) robuste. L'intégration se divise en plusieurs strates : matérielle, logicielle, ergonomique et réglementaire.

7.1.1 Architecture Matérielle : Le défi du "Edge Computing"

Actuellement, notre modèle 1D-CNN a été entraîné et testé sur une architecture d'ordinateur standard avec accélération CUDA. Dans un environnement hospitalier, les respirateurs ne disposent pas de telles ressources de calcul. Il n'est par ailleurs pas envisageable d'envoyer les données respiratoires brutes (échantillonnées à très haute fréquence) vers un serveur Cloud (Cloud Computing) pour analyse, en raison des risques de latence du réseau, des pannes de connexion et des contraintes strictes de confidentialité des données de santé.

La solution réside dans le **Edge Computing** (l'informatique en périphérie). Il s'agit d'intégrer des micro-accélérateurs d'intelligence artificielle directement dans ou à côté du moniteur de chevet :

- **Unités de Traitement Tensoriel (TPU)** : Des composants matériels comme le Google Coral Edge TPU ou les puces NVIDIA Jetson Nano permettent d'exécuter des réseaux de neurones complexes avec une consommation énergétique extrêmement faible (quelques watts seulement) et un encombrement minime.
- **Acquisition des signaux (Interfaçage)** : Le module embarqué devra être connecté directement aux ports de communication série (RS-232, USB) ou réseau (Ethernet) du ventilateur. Il faudra concevoir une carte d'acquisition capable de lire le flux de données en continu, de le bufferiser (mise en mémoire tampon des 500 derniers points de débit et de pression) et de l'injecter dans le modèle à une fréquence de quelques millisecondes.

7.1.2 Optimisation Logicielle : Quantification et Pruning

Pour qu'un modèle PyTorch pesant plusieurs mégaoctets puisse tourner de manière fluide sur un microcontrôleur ou un Edge TPU, il doit subir une phase d'optimisation mathématique sévère, sans pour autant sacrifier sa précision de 96%.

- **La Quantification (Quantization)** : Durant l'entraînement, les poids de notre réseau de neurones ont été calculés en virgule flottante sur 32 bits (Float32). La quantification consiste à convertir ces poids en entiers sur 8 bits (Int8). Cette opération divise par quatre la taille du modèle en mémoire et accélère exponentiellement la vitesse d'inférence, avec une perte de précision clinique généralement négligeable (inférieure à 1%).
- **L'Élagage (Pruning)** : Cette technique vise à identifier et à supprimer les connexions (synapses) entre les neurones qui ont un poids proche de zéro et qui contribuent peu à la décision finale. Un modèle élagué est plus léger et nécessite moins d'opérations matricielles (FLOPs) par cycle respiratoire.

7.1.3 Ergonomie et Interface Homme-Machine (IHM)

Si l'algorithme détecte une asynchronie avec succès, la manière dont cette information est restituée au clinicien est tout aussi vitale que la détection elle-même. Les unités de réanimation souffrent aujourd'hui d'un phénomène bien documenté : *la fatigue des alarmes* (Alarm Fatigue). Les soignants sont submergés par les signaux sonores constants, ce qui conduit parfois à la désactivation accidentelle d'alertes critiques.

Notre intégration sur moniteur de chevet doit donc repenser l'IHM :

1. **Alarmes visuelles non intrusives** : Plutôt que de déclencher une alarme sonore à chaque cyclage prématuré détecté, le système pourrait afficher un "Index d'Asynchronie" (Asynchrony Index - AI) mis à jour toutes les minutes. Si cet index (calculé comme le nombre d'asynchronies divisé par le total des cycles respiratoires) dépasse un seuil critique (par exemple 10%), le moniteur changera de couleur (passant du vert au jaune ou au rouge).
2. **Système d'Aide à la Décision (CDSS)** : L'interface ne doit pas se contenter de signaler le problème, elle doit proposer une action. En utilisant les principes d'explicabilité (SHAP/LIME) abordés au Chapitre 6, le moniteur pourrait surligner la zone anormale sur la courbe de débit et afficher un conseil technique ciblé, par exemple : "*Cyclage prématuré détecté récurrent (94% de confiance). Suggestion : Augmenter le temps inspiratoire ou ajuster le critère de cyclage expiratoire.*"

7.1.4 Sécurité, Cybersécurité et Normes Réglementaires

En tant que technologues en instrumentation biomédicale, nous savons qu’une innovation ne peut être déployée à l’hôpital sans répondre à un cadre normatif extrêmement strict. Un algorithme d’IA modifiant ou suggérant des modifications sur un dispositif de survie (Life-Support) est classé comme un Dispositif Médical (Software as a Medical Device - SaMD) de classe IIb ou III.

- **Norme ISO 13485 et Marquage CE** : Le développement du module IA embarqué devra suivre un processus de management de la qualité rigoureux, documentant chaque étape du code, chaque version du Dataset et chaque essai clinique.
- **Gestion des risques (ISO 14971)** : Une analyse des modes de défaillance (AMDEC) devra être réalisée. Que se passe-t-il si le capteur de débit du respirateur tombe en panne ou génère du bruit ? L’IA pourrait-elle interpréter ce bruit comme une asynchrone massive ? Des mécanismes de sécurité matériels (Watchdogs) et logiciels (détection d’anomalies de capteurs) devront être implémentés en amont du réseau de neurones.
- **Cybersécurité** : L’ajout d’un module d’analyse au réseau du respirateur ouvre une porte potentielle aux cyberattaques. Le transfert de données entre le respirateur et l’IA embarquée devra être crypté de bout en bout pour empêcher toute falsification des signaux physiologiques.

Conclusion générale

- Ce mémoire marque l'aboutissement dun travail de recherche et d'ingénierie passionnant, situé à la frontière entre la physiologie respiratoire, l'électronique embarquée et la science des données. Le défi initial était ambitieux : concevoir un système capable de surveiller de manière autonome, continue et précise l'interaction complexe entre un patient en détresse respiratoire et son ventilateur mécanique. Au regard de nos résultats — notamment une exactitude globale de 96 sur l'analyse de plus de 63 000 cycles simulés — nous pouvons affirmer que ce défi a été relevé avec succès.

D'un point de vue scientifique, nous avons démontré avec succès que les réseaux de neurones convolutifs unidimensionnels (1D-CNN) sont parfaitement adaptés au traitement des séries temporelles biomédicales. Le passage par un pipeline de données rigoureux — depuis l'extraction des signaux bruts de pression et de débit, le lissage, la segmentation temporelle, jusqu'à la mise en forme tensorielle — a constitué le socle de notre réussite.

L'entraînement de l'algorithme sur un jeu de données massif de plus de 63 000 cycles a permis au modèle de capturer les signatures morphologiques subtiles des asynchronies, notamment le cyclage prématuré. L'obtention d'une exactitude globale de 96% et d'un F1-Score de 0.93 pour la détection des anomalies prouve que la machine peut, sous certaines conditions, égaler voire surpasser l'il de l'expert humain dans une tâche de surveillance ininterrompue sur 24 heures.

Par ailleurs, l'exploration des méthodes d'explicabilité (XAI) comme SHAP et LIME a permis de démystifier la "boîte noire" de l'intelligence artificielle, prouvant que les décisions du modèle reposent sur des critères physiologiques réels et identifiables (comme la cassure du débit expiratoire), facilitant ainsi sa future acceptabilité clinique.

Sur le plan humain et professionnel, ce projet de fin d'études a représenté une véritable transition entre le monde académique et les exigences du terrain industriel et hospitalier. L'ancrage de cette recherche dans les réalités de l'instrumentation biomédicale a été profondément renforcé par mon expérience pratique. L'exposition directe à l'installation, à la maintenance préventive et au dépannage de dispositifs vitaux complexes m'a permis de saisir l'importance critique de la fiabilité de l'équipement. Le travail aux côtés d'équipes techniques chevronnées a mis en exergue que la théorie algorithmique doit impérativement s'accompagner d'une conception robuste, capable de résister aux conditions exigeantes des blocs opératoires et des services de réanimation.

Cette immersion, combinée à la rigueur scientifique exigée tout au long de mon cursus universitaire et lors de l'élaboration de ce manuscrit, a cristallisé ma vision de l'ingénierie biomédicale moderne. Elle a définitivement ancré ma volonté de m'orienter vers une licence à vocation industrielle, en parfaite adéquation avec mes objectifs professionnels. Le secteur médical a un besoin pressant d'ingénieurs capables de combler le fossé entre la recherche théorique en intelligence artificielle et l'application industrielle concrète, pour concevoir des dispositifs médicaux intelligents, sûrs et fabriqués à grande échelle.

En définitive, ce projet démontre que l'intelligence artificielle ne vise en aucun cas à remplacer le clinicien ou le technicien biomédical, mais plutôt à les doter d'un "sixième sens" techno-

logique. En automatisant la surveillance fastidieuse de la synchronisation patient-ventilateur, nous offrons au personnel soignant la possibilité de se reconcentrer sur l'essentiel : la prise en charge globale, humaine et personnalisée du patient. L'ingénierie biomédicale se doit de continuer dans cette voie, en plaçant toujours la haute technologie au service exclusif de la vie.

RÉFÉRENCES

- [1] Paout, J., Nmý, M., Mike, J., Jirman, J., Kubr, J., Niebauerová, E., Macík, M., Babuka, R., & Duka, F. (2025). *SmartAlert : Machine learning-based patient-ventilator asynchrony detection system in intensive care units*. Computer Methods and Programs in Biomedicine, 269, Article 108927. <https://doi.org/10.1016/j.cmpb.2025.108927>
- [2] Pan, Q., Jia, M., Liu, Q., Zhang, L., Pan, J., Lu, F., Zhang, Z., Fang, L., & Ge, H. (2021). *Identifying Patient Ventilator Asynchrony on a Small Dataset Using Image-Based Transfer Learning*. Sensors, 21(12), 4149. <https://doi.org/10.3390/s21124149>
- [3] Ang, C. Y. S., Chiew, Y. S., Wang, X., Ooi, E. H., Cove, M. E., Chen, Y., Zhou, C., & Chase, J. G. (2024). *Patient-ventilator asynchrony classification in mechanically ventilated patients : Model-based or machine learning method ?*. Computer Methods and Programs in Biomedicine, 255, Article 108323. <https://doi.org/10.1016/j.cmpb.2024.108323>
- [4] Liu, X., Wang, P., Hao, C., Miao, M. Y., An, X., Xu, S. S., Wang, Y., Li, H. L., Tian, Z., & Zhou, J. X. (2025). *Clinical and ventilator waveforms of Chinese patients during pressure support ventilation*. Scientific Data, 13, Article 48. <https://doi.org/10.1038/s41597-025-06364-z>
- [5] Pham, T., Montanya, J., Telias, I., Piraino, T., Magrans, R., Coudroy, R., Damiani, L. F., Artigas, R. M., Madorno, M., Blanch, L., & Brochard, L. (2021). *Automated detection and quantification of reverse triggering effort under mechanical ventilation*. Critical Care, 25, Article 60. <https://doi.org/10.1186/s13054-020-03387-3>
- [6] Sinderby, C., Liu, S., Colombo, D., Camarotta, G., Slutsky, A. S., Navalesi, P., & Beck, J. (2013). *An automated and standardized neural index to quantify patient-ventilator interaction*. Critical Care, 17, Article R239. <https://doi.org/10.1186/cc13063>
- [7] de Haro, C., Ochagavia, A., López-Aguilar, J., Fernandez-Gonzalo, S., Navarra-Ventura, G., Magrans, R., Montanyà, J., & Blanch, L. (2019). *Patient-ventilator asynchronies during mechanical ventilation : current knowledge and research priorities*. Intensive Care Medicine Experimental, 7(Suppl 1), Article 43. <https://doi.org/10.1186/s40635-019-0234-5>
- [8] Gholami, B., Phan, T. S., Haddad, W. M., Cason, A., Mullis, J., Price, L., & Bailey, J. M. (2018). *Replicating human expertise of mechanical ventilation waveform analysis in detecting patient-ventilator cycling asynchrony using machine learning*. Computers in Biology and Medicine, 97, 137-144. <https://doi.org/10.1016/j.compbimed.2018.04.016>
- [9] van Diepen, A., Bakkes, T. H. G. F., De Bie, A. J. R., Turco, S., Bouwman, R. A., Woerlee, P. H., & Mischi, M. (2022). *A model-based approach to generating annotated pressure support waveforms*. Journal of Clinical Monitoring and Computing, 36, 1739-1752. <https://doi.org/10.1007/s10877-022-00822-4>
- [10] Thille, A. W., Akoumianaki, E., & Hernández, G. (2026). *Patient-ventilator asynchrony : physiological causes and clinical aspects*. Intensive Care Medicine. <https://doi.org/10.1007/s00134-026-08312-w>

- [11] Kondili, E., Akoumianaki, E., Alexopoulou, C., & Georgopoulos, D. (2009). *Identifying and relieving asynchrony during mechanical ventilation*. Expert Review of Respiratory Medicine, 3(3), 231-243. <https://doi.org/10.1586/ers.09.21>
- [12] Murias, G., Lucangelo, U., & Blanch, L. (2016). *Patient-ventilator asynchrony*. Current Opinion in Critical Care, 22(1), 1-10. <https://doi.org/10.1097/MCC.0000000000000272>
- [13] de Bie, M. (2024). *Automated detection of Patient-Ventilator Asynchrony in Mechanically Ventilated Patients*. Master Thesis in Technical Medicine, Joint Degree Leiden University, TU Delft, and Erasmus University Rotterdam.
- [14] Blanch, L., Villagra, A., Sales, B., Montanya, J., Lucangelo, U., Baigorri, F., Chacón, E., Estruga, A., Murias, G., Fernandez, R., Kacmarek, R. M., & Mancebo, J. (2015). *Asynchronies during mechanical ventilation are associated with mortality*. Intensive Care Medicine, 41(4), 633-641. <https://doi.org/10.1007/s00134-015-3692-6>
- [15] Paszke, A., Gross, S., Massa, F., Lerer, A., Chintala, S., et al. (2019). *PyTorch : An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems, 32, 8024-8035.

ANNEXE A : SCRIPT PYTHON D'ENTRAÎNEMENT

Ce script détaille l'ensemble du pipeline de données développé au cours de ce projet : de l'extraction des cycles respiratoires à partir des fichiers CSV jusqu'à l'entraînement et l'évaluation du réseau de neurones convolutif 1D (CNNRespiratoire).

Code Source : main.py

```
import os
import glob
import pandas as pd
import numpy as np
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
from torch.utils.data import Dataset, DataLoader
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report,
    confusion_matrix

# =====
# 1. PARAMETRES GLOBAUX
# =====
DATA_FOLDER = "Waveforms.csv"
TOLERANCE_TIME = 0.1
PMUS_THRESHOLD = -1.0 # Seuil durci pour trouver les
    "Delayed"

# Detection automatique de la carte graphique (GPU) si
    disponible
device = torch.device("cuda" if torch.cuda.
    is_available() else "cpu")
print(f"Appareil utilise pour l'entrainement : {device
    }")

# =====
# 2. FONCTIONS DE TRAITEMENT DU SIGNAL
# =====
def extract_cycles(df):
    smoothed_flow = df['flow'].rolling(window=5, center=
        True).mean().fillna(0)
    is_positive = smoothed_flow > 0
```

```

crossings = (is_positive & ~is_positive.shift(1).
              fillna(False))
start_indices = df.index[crossings].tolist()

cycles = []
for i in range(len(start_indices) - 1):
    start_idx = start_indices[i]
    end_idx = start_indices[i + 1]
    cycle_df = df.iloc[start_idx:end_idx].copy()
    if len(cycle_df) > 50:
        cycles.append(cycle_df)
    return cycles

def label_cycle(cycle_df):
    expir_start_mask = cycle_df['flow'] < 0
    if not expir_start_mask.any():
        return None

    mech_end_time = cycle_df.loc[expir_start_mask, 'time'
                                ].iloc[0]
    pmus_active = cycle_df['pmus'] < PMUS_THRESHOLD
    if not pmus_active.any():
        return "None"

    pmus_times = cycle_df.loc[pmus_active, 'time']
    valid_pmus_times = pmus_times[pmus_times < (
        mech_end_time + 1.0)]

    if valid_pmus_times.empty:
        return "None"

    neural_end_time = valid_pmus_times.iloc[-1]
    time_diff = mech_end_time - neural_end_time

    if time_diff < -TOLERANCE_TIME:
        return "Premature"
    elif time_diff > TOLERANCE_TIME:
        return "Delayed"
    else:
        return "None"

# =====
# 3. PREPARATION PYTORCH (DATASET)
# =====
class AsynchronyDataset(Dataset):
    def __init__(self, cycles_df_list, labels_list,
                 max_len=500):
        self.data = []
        self.labels = []

# On definit 3 classes possibles

```

```

self.label_map = {"None": 0, "Premature": 1, "Delayed"
                  : 2}

for df, label in zip(cycles_df_list, labels_list):
    if label not in self.label_map:
        continue

    # Extraction de Flow et Paw uniquement
    sig = df[['flow', 'paw']].values

    # Padding ou Troncature
    if len(sig) > max_len:
        sig = sig[:max_len]
    else:
        pad_len = max_len - len(sig)
        sig = np.pad(sig, ((0, pad_len), (0, 0)), mode='
            constant')

    sig = sig.T # Format (Variables, Temps)

    self.data.append(sig)
    self.labels.append(self.label_map[label])

self.data = torch.tensor(np.array(self.data), dtype=
    torch.float32)
self.labels = torch.tensor(self.labels, dtype=torch.
    long)

def __len__(self):
    return len(self.data)

def __getitem__(self, idx):
    return self.data[idx], self.labels[idx]

# =====
# 4. ARCHITECTURE DU MODELE DE DEEP LEARNING
# =====
class CNNRespiratoire(nn.Module):
    def __init__(self, num_classes=3):
        super(CNNRespiratoire, self).__init__()
        self.conv1 = nn.Conv1d(in_channels=2, out_channels=16,
            kernel_size=5, padding=2)
        self.pool1 = nn.MaxPool1d(kernel_size=2)
        self.conv2 = nn.Conv1d(in_channels=16, out_channels
            =32, kernel_size=5, padding=2)
        self.pool2 = nn.MaxPool1d(kernel_size=2)
        self.conv3 = nn.Conv1d(in_channels=32, out_channels
            =64, kernel_size=3, padding=1)
        self.pool3 = nn.MaxPool1d(kernel_size=2)

        self.fc1 = nn.Linear(64 * 62, 128)
        self.dropout = nn.Dropout(0.5)

```

```

self.fc2 = nn.Linear(128, num_classes)

def forward(self, x):
x = self.pool1(F.relu(self.conv1(x)))
x = self.pool2(F.relu(self.conv2(x)))
x = self.pool3(F.relu(self.conv3(x)))
x = torch.flatten(x, 1)
x = F.relu(self.fc1(x))
x = self.dropout(x)
x = self.fc2(x)
return x

# =====
# 5. BOUCLE PRINCIPALE (EXTRACTION & ENTRAÎNEMENT)
# =====
if __name__ == "__main__":
print("\n--- PHASE 1 : EXTRACTION DES SIGNAUX ---")
all_files = glob.glob(os.path.join(DATA_FOLDER, "*.csv"))

tous_les_cycles = []
tous_les_labels = []

for file_path in all_files:
try:
df = pd.read_csv(file_path)
if 'pmus' not in df.columns:
print(f"Ignore: {os.path.basename(file_path)} (pas de colonne 'pmus')")
continue

cycles = extract_cycles(df)
for cycle in cycles:
label = label_cycle(cycle)
if label is not None:
tous_les_cycles.append(cycle)
tous_les_labels.append(label)
except Exception as e:
print(f"Erreur sur {file_path}: {e}")

print(f"\nExtraction terminée. {len(tous_les_labels)} cycles trouvés.")

if len(tous_les_labels) > 100:
print("\n--- PHASE 2 : PRÉPARATION DE L'IA ---")
X_train_raw, X_test_raw, y_train_raw, y_test_raw =
train_test_split(
tous_les_cycles, tous_les_labels, test_size=0.2,
random_state=42, stratify=tous_les_labels
)

train_dataset = AsynchronyDataset(X_train_raw,

```

```

        y_train_raw)
test_dataset = AsynchronyDataset(X_test_raw,
    y_test_raw)

train_loader = DataLoader(train_dataset, batch_size
    =64, shuffle=True)
test_loader = DataLoader(test_dataset, batch_size=64,
    shuffle=False)

modele = CNNRespiratoire(num_classes=3).to(device)
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(modele.parameters(), lr=0.001)

print("\n--- PHASE 3 : ENTRAÎNEMENT DU RESEAU DE
    NEURONES ---")
num_epochs = 10

for epoch in range(num_epochs):
    modele.train()
    running_loss = 0.0

    for signaux, labels in train_loader:
        signaux, labels = signaux.to(device), labels.to(device
        )

        optimizer.zero_grad()
        outputs = modele(signaux)
        loss = criterion(outputs, labels)
        loss.backward()
        optimizer.step()

    running_loss += loss.item()

    print(f"Epoque {epoch+1}/{num_epochs} - Erreur (Loss
        ): {running_loss/len(train_loader):.4f}")

print("\n--- PHASE 4 : EVALUATION FINALE ---")
modele.eval()
all_preds = []
all_targets = []

with torch.no_grad():
    for signaux, labels in test_loader:
        signaux, labels = signaux.to(device), labels.to(device
        )
        outputs = modele(signaux)

    _, predicted = torch.max(outputs.data, 1)

    all_preds.extend(predicted.cpu().numpy())
    all_targets.extend(labels.cpu().numpy())

reverse_map = {0: "None", 1: "Premature", 2: "Delayed"

```

```

    }
    noms_cibles = [reverse_map[i] for i in sorted(list(set
        (all_targets)))]

    print("\nMatrice de Confusion:")
    print(confusion_matrix(all_targets, all_preds))

    print("\nRapport de Classification:")
    print(classification_report(all_targets, all_preds,
        target_names=noms_cibles))

    else:
    print("Pas assez de donnees pour entrainer le Deep
        Learning.")

```

ANNEXE B : LOGS D'EXÉCUTION DU TERMINAL

Cette annexe présente la capture textuelle brute de la console d'exécution. Ces indicateurs valident de manière matérielle la convergence de notre algorithme d'apprentissage profond sous l'environnement d'accélération matérielle NVIDIA CUDA, ainsi que la génération des métriques statistiques de validation.

Terminal : Console de Sortie

```
C:\Users\Victus\Desktop\monprojet\.venv\Scripts\python
.exe C:\Users\Victus\Desktop\monprojet\main.py
Appareil utilise pour l'entrainement : cuda

--- PHASE 1 : EXTRACTION DES SIGNAUX ---
Ignore: Run622.csv (pas de colonne 'pmus')
Ignore: Run623.csv (pas de colonne 'pmus')
Ignore: Run624.csv (pas de colonne 'pmus')
Ignore: Run625.csv (pas de colonne 'pmus')
Ignore: Run626.csv (pas de colonne 'pmus')
Ignore: Run627.csv (pas de colonne 'pmus')
Ignore: Run628.csv (pas de colonne 'pmus')
Ignore: Run629.csv (pas de colonne 'pmus')
Ignore: Run630.csv (pas de colonne 'pmus')

Extraction terminee. 63857 cycles trouves.

--- PHASE 2 : PREPARATION DE L'IA ---

--- PHASE 3 : ENTRAINEMENT DU RESEAU DE NEURONES ---
Epoque 1/10 - Erreur (Loss): 0.4354
Epoque 2/10 - Erreur (Loss): 0.3119
Epoque 3/10 - Erreur (Loss): 0.2287
Epoque 4/10 - Erreur (Loss): 0.1797
Epoque 5/10 - Erreur (Loss): 0.1552
Epoque 6/10 - Erreur (Loss): 0.1406
Epoque 7/10 - Erreur (Loss): 0.1338
Epoque 8/10 - Erreur (Loss): 0.1295
Epoque 9/10 - Erreur (Loss): 0.1212
Epoque 10/10 - Erreur (Loss): 0.1173

--- PHASE 4 : EVALUATION FINALE ---

Matrice de Confusion :
[[9002  218]
```

```
[ 290 3262]]
```

```
Rapport de Classification :
```

```
precision      recall  f1-score      support
```

```
None           0.97          0.98          0.97          9220
```

```
Premature      0.94          0.92          0.93          3552
```

```
accuracy                                0.96          12772
```

```
macro avg      0.95          0.95          0.95          12772
```

```
weighted avg   0.96          0.96          0.96          12772
```

```
Process finished with exit code 0
```