



Royaume du Maroc
Université Hassan 1^{er}
*Institut Supérieur des Sciences de la
Santé*



N° Ordre :/2026

Mémoire de projet de fin d'études

Présenté pour obtenir

La licence en :

Technologue en instrumentation et maintenance biomédicale

Identification automatique des asynchronies patient-ventilateur

Réalisé par :

Mr. LEKCHIRI Mohammed

Encadré par :

Pr. LYAZIDI Aissam

Soutenu publiquement le 08/06/2026

Devant le jury :

Pr.

Pr.

Pr.

Pr.

Année universitaire : 2025/2026

*La volonté permet de grimper sur les cimes,
sans volonté on reste au pied de la montagne.*

- Victor Hugo

DÉDICACES

À mes parents,

*À la lumière de la vie qui a éclairé mon chemin et dissipé mes doutes.
Vous êtes le souffle originel qui a nourri mes ambitions, et la force bienveillante
qui ne m'a jamais fait défaut. Si la volonté m'a permis de gravir la montagne,
c'est votre amour inconditionnel et vos sacrifices silencieux qui m'ont donné
l'énergie d'en atteindre le sommet.*

*À ma mère, mon refuge et ma source inépuisable de tendresse.
À mon père, ma boussole et mon pilier inébranlable.*

*Ce modeste travail n'est que le reflet de ce que vous m'avez offert :
la patience de comprendre le monde et le courage d'y avancer.
Que ce mémoire soit l'hommage de mon immense gratitude.*

REMERCIEMENTS

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué à la réalisation de ce projet de fin d'études.

Tout d'abord, je remercie chaleureusement mes encadrants pédagogiques, mon encadrant le professeur Aissam Lyazidi et le professeur Elmaati Essoukaki, pour leur précieuse guidance, leurs conseils avisés et leur soutien constant tout au long de cette recherche. Leurs compétences et leur expertise ont été d'une aide inestimable pour mener à bien ce projet.

Je souhaite également remercier l'ensemble du corps professoral et administratif de l'Institut Supérieur des Sciences de la Santé (ISSS), pour avoir fourni un environnement académique stimulant et enrichissant. Vos enseignements et votre accompagnement m'ont permis d'acquérir les connaissances et compétences nécessaires en instrumentation et maintenance biomédicale pour entreprendre ce travail. Je tiens à exprimer ma gratitude à mes professeurs pour m'avoir incité à me dépasser en me faisant bénéficier de leurs expériences et compétences.

Un remerciement particulier s'adresse à toute l'équipe de la Société Commerciale de Représentation Industrielle et Médicale (SCRIM) à Casablanca, qui m'a accueilli lors de mon stage. Je remercie tout particulièrement Monsieur Fouad El Ouafi, responsable technique, pour son accueil et son encadrement.

Je tiens à adresser ma reconnaissance la plus sincère et toute spéciale à Hamza Zeroual et Mehdi Ghiyat, de véritables experts d'intervention sur le terrain. J'ai énormément appris à leurs côtés ; leur pédagogie, leur patience et le généreux partage de leur savoir-faire technique m'ont permis de lier la théorie académique à la réalité exigeante du terrain dans d'excellentes conditions.

Enfin, mes pensées les plus affectueuses vont à ma famille, et particulièrement à mes parents, pour leur soutien moral et matériel indéfectible, ainsi que pour leurs encouragements constants. Leur amour et leur confiance en moi ont été une source de motivation permanente.

À tous, je vous dis sincèrement merci.

RÉSUMÉ

La ventilation mécanique est une intervention vitale en soins intensifs, mais son efficacité repose grandement sur une interaction optimale entre le patient et le respirateur. La synchronisation patient-ventilateur demeure un défi clinique majeur, car les asynchronies peuvent entraîner un inconfort, une augmentation du travail respiratoire et une prolongation de la durée de ventilation.

Ce document explore les différents types d'asynchronies, telles que les efforts inefficaces, les doubles déclenchements et les retards de cyclage. Ces anomalies surviennent lorsqu'il y a un décalage entre la commande neurologique respiratoire du patient et l'assistance pneumatique fournie par la machine, affectant directement la qualité de la prise en charge.

Afin d'optimiser cette interaction, diverses stratégies de monitoring et d'adaptation sont analysées. Des technologies avancées, allant de l'analyse fine des courbes de pression et de débit à l'utilisation d'outils spécifiques comme le monitoring de l'activité électrique du diaphragme (NAVA) ou de la pression sophagienne, permettent aujourd'hui une détection plus précoce et précise des défauts de synchronisation.

En conclusion, l'amélioration de la synchronisation patient-ventilateur est essentielle pour réduire les complications associées à la ventilation artificielle. L'intégration de ces outils de surveillance permet une gestion plus proactive et personnalisée des réglages du ventilateur, favorisant ainsi le confort du patient, accélérant le processus de sevrage et améliorant globalement le pronostic clinique.

SUMMARY

Mechanical ventilation is a life-saving intervention in intensive care, but its effectiveness relies heavily on optimal interaction between the patient and the ventilator. Patient-ventilator synchronization remains a major clinical challenge, as asynchronies can lead to discomfort, increased work of breathing, and prolonged duration of mechanical ventilation.

This document explores the different types of asynchronies, such as ineffective efforts, double triggering, and cycling delays. These anomalies occur when there is a mismatch between the patient's neural respiratory drive and the pneumatic assistance provided by the machine, directly affecting the quality of patient care.

To optimize this interaction, various monitoring and adaptation strategies are analyzed. Advanced technologies, ranging from the detailed analysis of pressure and flow waveforms to the use of specific tools like Neurally Adjusted Ventilatory Assist (NAVA) or esophageal pressure monitoring, now allow for earlier and more accurate detection of synchronization issues.

In conclusion, improving patient-ventilator synchronization is essential to reduce complications associated with artificial ventilation. Integrating these monitoring tools enables more proactive and personalized management of ventilator settings, thereby promoting patient comfort, accelerating the weaning process, and improving overall clinical outcomes.

TABLE DES MATIÈRES

DÉDICACES	iii
REMERCIEMENTS	iv
RÉSUMÉ	v
SUMMARY	vi
TABLE DES FIGURES	viii
LISTE DES TABLEAUX	ix
LISTE DES SIGLES ET ABRÉVIATIONS	x
Chapitre Premier : Rapport de stage	1
1.1 Présentation de la SCRIM	1
1.1.1 Présentation de l'entreprise	1
1.1.2 Organigramme de l'entreprise	1
1.1.3 Le Service Technique et Biomédical	1
1.2 Rapport de Stage	2
Chapitre Deux : Projet de fin d'étude	5
2.1 Problématique : Limites de la détection visuelle des APV	5
2.1.1 La charge de la détection manuelle	5
2.1.2 Conséquences cliniques du sous-diagnostic	6
2.2 Objectif : Automatisation par Deep Learning	6
2.2.1 La puissance de l'Intelligence Artificielle	6
2.2.2 Bénéfices attendus du projet	6
Chapitre Trois : État de l'art et signaux	8
3.1 Caractérisation des asynchronies	8
3.1.1 Le Double Déclenchement (Double Triggering)	8
3.1.2 Les Fuites (Leaks) et l'Auto-déclenchement	8
3.1.3 Autres asynchronies majeures (Aperçu)	9
3.2 Analyse du signal ventilatoire (Débit/Pression)	9
3.2.1 La courbe de Pression-Temps ($P_{aw} - t$)	9
3.2.2 La courbe de Débit-Temps ($Q - t$)	9
3.2.3 Corrélation des signaux pour l'Intelligence Artificielle	10
Chapitre Quatre : Ingénierie des données (Data Pipeline)	11
4.1 Génération et segmentation du Dataset simulé	11
4.1.1 L'avantage des données simulées (In Silico)	11
4.1.2 Filtrage et lissage du signal	12
4.1.3 Délimitation automatique des cycles respiratoires	12
4.2 Étiquetage (Labeling) et Préparation Tensorielle	12
4.2.1 Annotation automatisée via la pression musculaire (P_{mus})	12
4.2.2 Normalisation et mise en forme tensorielle	13

Chapitre Cinq : Conception de l'algorithme d'IA	14
5.1 Choix de l'architecture : Le CNN-1D pour séries temporelles	14
5.1.1 Avantages par rapport aux réseaux récurrents	14
5.2 Anatomie du modèle CNNRespiratoire	14
5.2.1 Les couches de convolution (Feature Extraction)	15
5.2.2 Réduction de dimension et Sous-échantillonnage	15
5.2.3 La couche dense et la régularisation par Dropout	15
5.3 Stratégie d'entraînement et Optimisation	16
5.3.1 Fonction de perte : CrossEntropy Loss	16
5.3.2 Algorithme d'optimisation : Adam	16
5.3.3 Hardware et accélération CUDA	16
5.4 Analyse du processus d'apprentissage	16
 Chapitre Six : Performance et validation	 18
6.1 Métriques d'évaluation (Précision, Rappel, F1-Score)	18
6.1.1 Définitions mathématiques des métriques	19
6.1.2 Analyse des résultats par classe	19
6.2 Analyse de la Matrice de Confusion	19
6.2.1 Interprétation des résultats de la matrice	20
6.3 Interprétabilité des résultats (SHAP/LIME)	20
6.3.1 SHAP (SHapley Additive explanations)	20
6.3.2 LIME (Local Interpretable Model-agnostic Explanations)	21
6.3.3 Le mécanisme de LIME sur les séries temporelles	21
Conclusion sur la validation du modèle	21
 Chapitre Sept : Discussion et perspectives	 22
7.1 Intégration sur moniteur de chevet	22
7.1.1 Architecture Matérielle : Le défi du "Edge Computing"	22
7.1.2 Optimisation Logicielle : Quantification et Pruning	23
7.1.3 Ergonomie et Interface Homme-Machine (IHM)	23
7.1.4 Sécurité, Cybersécurité et Normes Réglementaires	24
7.2 Conclusion générale	24
7.2.1 Bilan Technique et Scientifique	24
7.2.2 Bilan Professionnel et Personnel	24
 RÉFÉRENCES	 26
ANNEXE A : SCRIPT PYTHON D'ENTRAÎNEMENT	28
ANNEXE B : LOGS D'EXÉCUTION DU TERMINAL	34

Table des figures

1.1	Configuration d'un bloc opératoire complet : équipements suspendus et table d'opération.	2
1.2	Installation active de respirateurs par les techniciens biomédicaux.	3
1.3	Poste de monitoring central : visualisation des scopes sur grands écrans.	3
4.1	Représentation graphique temporelle des données simulées illustrant le Débit, la Pression dans les voies aériennes (P_{aw}) et la Pression musculaire (P_{mus}).	12
5.1	Architecture détaillée du réseau de neurones convolutif 1D (CNN-1D) conçu pour l'analyse des cycles respiratoires (2 canaux en entrée, 3 classes en sortie).	15

Liste des tableaux

6.1	Rapport de classification généré par l'algorithme 1D-CNN sur l'ensemble de test.	19
6.2	Matrice de confusion du réseau CNNRespiratoire.	20

Liste des Sigles et Abréviations

1D-CNN	Convolutional Neural Network 1D (Réseau de Neurones Convolutif 1D)
AMDEC	Analyse des Modes de Défaillance, de leurs Effets et de leur Criticité
APV	Asynchronie Patient-Ventilateur
CHU	Centre Hospitalier Universitaire
IA	Intelligence Artificielle
ISSS	Institut Supérieur des Sciences de la Santé
NAVA	Neurally Adjusted Ventilatory Assist
PEP (PEEP)	Pression Expiratoire Positive
P_{mus}	Pression musculaire
SAV	Service Après-Vente
SCRIM	Société Commerciale de Représentation Industrielle et Médicale
VNI	Ventilation Non Invasive

Chapitre 1

Rapport de stage

1.1 Présentation de la Société Commerciale de Représentation Industrielle et Médicale (SCRIM)

1.1.1 Présentation de l'entreprise

La Société Commerciale de Représentation Industrielle et Médicale (SCRIM), basée à Casablanca, est un acteur majeur dans le domaine de la distribution, de l'installation et de la maintenance d'équipements médicaux et scientifiques au Maroc. Représentant des marques internationales de renommée, SCRIM joue un rôle d'intermédiaire privilégié entre les constructeurs mondiaux de dispositifs médicaux et les établissements de santé marocains (hôpitaux publics, CHU, cliniques privées et laboratoires).

L'entreprise s'engage non seulement à fournir des équipements de pointe (tels que les respirateurs artificiels, les générateurs d'hémodialyse, l'imagerie médicale et le monitoring), mais assure également un accompagnement complet allant de l'installation initiale à la maintenance, garantissant ainsi la pérennité des équipements et la sécurité des patients.

1.1.2 Organigramme de l'entreprise

Contrairement à la structure hospitalière, l'organisation de SCRIM est orientée vers la satisfaction client et la réactivité technique. Elle s'articule généralement autour de plusieurs pôles :

- **La Direction Générale** : Définit la stratégie et gère les partenariats avec les fournisseurs internationaux.
- **Le Service Commercial** : En charge de la réponse aux appels d'offres, de la vente et du conseil auprès des établissements de santé.
- **Le Service Technique et Biomédical (Service Après-Vente - SAV)** : Le cœur technique de l'entreprise, responsable de l'installation, de la mise en service, et de la maintenance (préventive et corrective) des équipements sur le terrain.
- **Le Service Logistique et Administratif** : Gère les stocks de pièces de rechange, les importations et l'administration des ventes.

1.1.3 Le Service Technique et Biomédical

Le service technique est le garant du bon fonctionnement des dispositifs médicaux vendus par SCRIM. Sous la supervision du responsable technique, Monsieur Fouad, et soutenu par une équipe de techniciens expérimentés tels que Messieurs Hamza et Mehdi, ce département est essentiel pour maintenir la confiance des clients.

Rôle et Missions du service

1. **Installation et mise en service** : Déploiement des nouveaux équipements au sein des blocs opératoires, des services de réanimation ou d'imagerie.
2. **Maintenance Préventive** : Réalisation des visites périodiques planifiées pour remplacer les pièces d'usure, calibrer les capteurs et garantir les performances d'origine des machines.
3. **Maintenance Corrective (Dépannage)** : Intervention rapide sur site ou en atelier suite à des signalements de panne pour minimiser le temps d'indisponibilité du matériel.
4. **Contrôle Qualité et Sécurité** : Vérification de la sécurité électrique et métrologique des appareils à l'aide de testeurs biomédicaux certifiés (analyseurs de débit, testeurs de sécurité électrique).

1.2 Rapport de Stage

Au terme de ce stage au sein de SCRIM, j'ai eu l'opportunité de m'immerger pleinement dans le rôle d'un spécialiste en instrumentation et maintenance biomédicale. Intégré au sein de l'équipe technique, j'ai pu lier mes connaissances théoriques acquises à l'ISSS à la réalité exigeante du terrain. Mes missions ont couvert l'ensemble du cycle de vie technique des dispositifs médicaux :

Installation et Mise en Service

J'ai participé activement à l'assemblage, au paramétrage et à la mise en service de divers équipements (notamment des dispositifs d'assistance respiratoire et de dialyse) au sein des établissements de santé. Cette étape implique le respect strict des protocoles d'installation dictés par les constructeurs et la réalisation de tests à blanc avant toute utilisation sur des patients.




FIGURE 1.1 : Configuration d'un bloc opératoire complet : équipements suspendus et table d'opération.



FIGURE 1.2 : Installation active de respirateurs par les techniciens biomédicaux.

Maintenance Préventive et Tests de Sécurité

La prévention étant primordiale dans le secteur médical, j'ai accompagné les techniciens lors des campagnes de maintenance. J'ai appris à utiliser des analyseurs biomédicaux pour vérifier la calibration des capteurs (pression, volume, débit) et à effectuer des tests de sécurité électrique (courants de fuite, résistance de terre) afin de prévenir tout risque de fibrillation ou d'électrisation.




FIGURE 1.3 : Poste de monitoring central : visualisation des scopes sur grands écrans.

Diagnostic et Maintenance Corrective

Face à des équipements en panne, j'ai été formé à la méthodologie de dépannage : analyse des codes d'erreur, lecture des schémas électroniques et pneumatiques, isolation de la carte ou du composant défectueux, et remplacement des pièces. Cette mission m'a permis de développer une grande capacité d'analyse et de résolution de problèmes complexes sous pression.

Formation des Utilisateurs et Traçabilité

Le travail biomédical ne se limite pas à la machine. J'ai assisté l'équipe lors des sessions de formation du personnel soignant pour garantir une utilisation optimale et sécurisée des équipements. De plus, j'ai pris part à la rédaction des fiches d'intervention et à la mise à jour de la base de données technique de l'entreprise, soulignant l'importance de la traçabilité documentaire pour le suivi de chaque dispositif médical.

Conclusion Générale

Ce stage chez SCRIM a été une expérience profondément formatrice. Il m'a offert une vision globale du métier de biomédical dans le secteur privé et de la distribution. En travaillant aux côtés de Monsieur Fouad, Hamza et Mehdi, j'ai acquis des compétences pratiques pointues et compris que la rigueur, l'adaptabilité et la réactivité sont les piliers indispensables pour garantir la sécurité des soins à travers la fiabilité des équipements médicaux.

Chapitre 2

Projet de fin d'étude

2.1 Problématique : Limites de la détection visuelle des APV

La ventilation mécanique est l'un des piliers de la prise en charge en unité de soins intensifs et en réanimation. Son objectif principal est de suppléer ou d'assister la fonction respiratoire défaillante du patient. Cependant, pour que cette assistance soit optimale, il est impératif que le ventilateur s'adapte parfaitement à la demande neurologique et mécanique du patient. Lorsque cette harmonie est rompue, on parle d'Asynchronies Patient-Ventilateur (APV).

2.1.1 La charge de la détection manuelle

Historiquement, et encore majoritairement aujourd'hui, l'identification de ces asynchronies repose sur l'analyse visuelle des courbes de monitoring affichées sur l'écran du respirateur (principalement les courbes de pression, de débit et de volume en fonction du temps).

Bien que les cliniciens (réanimateurs, anesthésistes, kinésithérapeutes) soient formés à reconnaître les anomalies typiques telles que les efforts inefficaces, les doubles déclenchements ou les retards de cyclage, cette méthode d'évaluation visuelle présente de nombreuses limites intrinsèques :

- **La subjectivité et l'expertise requise** : L'interprétation des formes d'ondes respiratoires nécessite un niveau d'expertise élevé. Des études montrent qu'une proportion significative d'asynchronies passe inaperçue, même auprès de professionnels expérimentés, car les altérations des courbes peuvent être subtiles ou noyées dans des artefacts (mouvements du patient, sécrétions, toux).
- **L'impossibilité d'une surveillance continue** : Un patient sous assistance respiratoire effectue en moyenne entre 15 000 et 25 000 cycles respiratoires par jour. Il est humainement impossible pour le personnel soignant de scruter l'écran du moniteur 24 heures sur 24. L'évaluation visuelle ne représente donc qu'un "instantané" (souvent de quelques minutes) de la situation du patient, ignorant totalement les épisodes asynchrones nocturnes ou survenant hors de la présence du médecin.
- **La charge cognitive et le manque de temps** : Dans un service de réanimation où la charge de travail est intense, analyser finement des courbes respiratoires cycle par cycle est extrêmement chronophage. Le temps médical est précieux et la détection manuelle des APV est souvent reléguée au second plan face aux urgences vitales immédiates.

2.1.2 Conséquences cliniques du sous-diagnostic

L'incapacité à détecter et corriger systématiquement ces asynchronies n'est pas sans conséquence. Les APV non résolues entraînent une augmentation significative du travail respiratoire, de l'inconfort, un besoin accru de sédation et, à terme, une fatigue des muscles respiratoires (notamment le diaphragme). Cela se traduit cliniquement par des durées de ventilation mécanique prolongées, un sevrage respiratoire plus difficile, et une augmentation globale de la morbidité et de la mortalité en réanimation.

2.2 Objectif : Automatisation par Deep Learning

Face aux limitations critiques de l'analyse visuelle humaine, il devient impératif de développer des outils capables d'assister les cliniciens en surveillant, quantifiant et classifiant les asynchronies de manière continue, objective et automatisée. C'est ici que l'Intelligence Artificielle (IA) intervient comme une solution de rupture technologique.

2.2.1 La puissance de l'Intelligence Artificielle

L'objectif principal de ce projet de fin d'études est de concevoir et d'implémenter un algorithme d'identification automatique des APV en s'appuyant sur des techniques avancées d'apprentissage profond (Deep Learning). Contrairement aux algorithmes déterministes classiques, qui reposent sur des seuils fixes (ex : déclencher une alarme si la pression dépasse X cmH₂O) et génèrent de nombreuses fausses alarmes, le Deep Learning excelle dans la reconnaissance de motifs complexes au sein de grandes masses de données.

Le projet s'articule autour des objectifs technologiques suivants :

1. **Extraction et traitement des signaux bruts** : Récupérer les données temporelles à haute fréquence (signaux de débit et de pression) directement depuis le ventilateur, et les nettoyer de leurs bruits physiologiques ou mécaniques.
2. **Exploitation des architectures Deep Learning** : Utiliser la puissance de calcul moderne (notamment via des bibliothèques open-source spécialisées comme PyTorch) pour entraîner un réseau de neurones. L'approche consistera à analyser ces séries temporelles, soit en utilisant des architectures adaptées à l'analyse séquentielle, soit en adaptant des modèles d'ordinaire utilisés en vision par ordinateur pour analyser la "topologie" des cycles respiratoires.
3. **Classification temps réel** : Aboutir à un modèle capable, pour chaque cycle respiratoire analysé, de déterminer avec une haute précision s'il s'agit d'un cycle normal ou d'un cycle asynchrone, et d'en identifier la sous-classe (double déclenchement, effort inefficace, etc.).

2.2.2 Bénéfices attendus du projet

En automatisant cette détection via le Deep Learning, nous visons à transformer le moniteur du respirateur : d'un simple afficheur de courbes brutes, il deviendrait un véritable assistant diagnostique (Système d'Aide à la Décision Clinique).

Les bénéfices attendus sont majeurs :

- Fournir aux réanimateurs un **index d'asynchronie** calculé en continu sur 24h, permettant d'objectiver la qualité de l'interaction patient-machine.

- Réduire drastiquement la charge cognitive des équipes soignantes.
- Permettre un ajustement précoce et ciblé des paramètres ventilatoires (PEEP, Trigger, temps inspiratoire), favorisant ainsi le confort du patient et un sevrage plus rapide de la ventilation mécanique.

En somme, ce projet d'ingénierie biomédicale se positionne à la convergence de l'instrumentation médicale traditionnelle et des sciences de la donnée, avec pour finalité directe l'amélioration de la qualité des soins en réanimation.

Chapitre 3

État de l'art et signaux

L'interaction entre un patient et un ventilateur mécanique repose sur un équilibre fragile. Pour comprendre comment une intelligence artificielle peut identifier les défauts de cette interaction, il est indispensable de maîtriser la physiopathologie des asynchronies et la morphologie des signaux générés par les capteurs du respirateur. Ce chapitre dresse l'état de l'art des principales anomalies et détaille l'analyse des signaux ventilatoires.

3.1 Caractérisation des asynchronies

Une asynchronie patient-ventilateur (APV) survient lorsqu'il y a un décalage temporel ou quantitatif entre la commande respiratoire neurale du patient (ce que son cerveau demande) et l'assistance pneumatique délivrée par la machine (ce que le ventilateur fournit). Parmi les multiples types d'APV, certaines sont particulièrement critiques et fréquentes en réanimation.

3.1.1 Le Double Déclenchement (Double Triggering)

Le double déclenchement est l'une des asynchronies les plus délétères pour les poumons du patient. Il se produit lorsque le temps inspiratoire neuronal du patient est significativement plus long que le temps inspiratoire mécanique réglé sur le ventilateur.

Mécanisme : Le ventilateur termine son cycle inspiratoire et ouvre la valve expiratoire, mais le patient continue de faire un effort inspiratoire (contraction diaphragmatique). Si cet effort est suffisant, il va "déclencher" (trigger) un deuxième cycle mécanique consécutif avant même que l'expiration du premier cycle n'ait pu avoir lieu.

Conséquences cliniques :

- **Volutrauma et Barotrauma :** Le volume courant du second cycle s'ajoute au volume non expiré du premier, entraînant une surdistension alvéolaire massive (le volume empilé peut atteindre le double du volume consigné).
- **Inconfort majeur :** Cette asynchronie provoque une sensation d'étouffement chez le patient, augmentant l'anxiété et la consommation d'oxygène.

3.1.2 Les Fuites (Leaks) et l'Auto-déclenchement

Bien que les fuites soient techniquement un problème d'étanchéité mécanique plutôt qu'une anomalie neurologique, elles perturbent dramatiquement la synchronisation en trompant les capteurs du respirateur. Elles surviennent fréquemment en Ventilation Non Invasive (VNI) au niveau du masque, ou en ventilation invasive au niveau du ballonnet de la sonde d'intubation ou du circuit patient.

L'Auto-déclenchement (Auto-triggering) : C'est la conséquence la plus directe d'une fuite importante. En mode déclenchement en débit (Flow Trigger), le ventilateur interprète une baisse du débit de base due à une fuite comme un effort inspiratoire du patient. La machine va alors insuffler un cycle sans qu'aucune demande physiologique ne l'ait initié. Si la fuite est continue, cela peut générer une hyperventilation artificielle et une alcalose respiratoire.

3.1.3 Autres asynchronies majeures (Aperçu)

Pour concevoir un modèle d'Intelligence Artificielle robuste, il est également crucial de connaître les autres asynchronies qui peuvent se superposer dans les données :

- **L'effort inefficace (Ineffective effort) :** Le patient tente d'inspirer, mais son effort est trop faible pour vaincre le seuil de déclenchement du respirateur (souvent causé par une auto-PEEP élevée ou une faiblesse musculaire).
- **Le cyclage prématuré ou tardif :** Un décalage à la fin de l'inspiration, où la machine passe en phase expiratoire trop tôt (frustration inspiratoire) ou trop tard (freinage expiratoire) par rapport au temps neural du patient.

3.2 Analyse du signal ventilatoire (Débit/Pression)

Pour le technicien biomédical comme pour l'algorithme de Deep Learning, la détection de ces asynchronies repose sur l'analyse fine des séries temporelles acquises à haute fréquence par les pneumotachographes et les capteurs de pression du respirateur.

3.2.1 La courbe de Pression-Temps ($P_{aw} - t$)

Ce signal représente la pression dans les voies aériennes au cours du temps. En fonctionnement normal, la courbe débute à la valeur de la Pression Expiratoire Positive (PEP). Lors de l'inspiration, la pression monte jusqu'à une Pression de Crête (PIP), puis redescend à la PEP lors de l'expiration.

Signature visuelle des anomalies sur la pression :

- **En cas d'effort inefficace :** On observe une légère déflexion négative (creux) sur le plateau expiratoire de la courbe de pression, signe que le patient "tire" sur un circuit fermé sans déclencher de cycle.
- **En cas d'asynchronie de flux (Flow starvation) :** La courbe de pression, au lieu d'avoir un aspect convexe ou plat pendant l'insufflation, se creuse (aspect concave). Le patient demande plus de débit que ce que la machine fournit, créant une dépression relative.

3.2.2 La courbe de Débit-Temps ($Q - t$)

C'est le signal le plus riche en informations dynamiques. L'inspiration est représentée par une aire positive (débit entrant) et l'expiration par une aire négative (débit sortant).

Détection des Fuites sur le débit : Une fuite se lit instantanément sur cette courbe. En temps normal, le débit expiratoire doit revenir exactement à zéro avant le début du cycle suivant. S'il y a une fuite, la courbe expiratoire s'aplatit et ne rejoint jamais la ligne de base (le zéro). L'écart entre la ligne de base et la fin de l'expiration représente le volume de fuite continu.

Détection du Double Déclenchement sur le débit : Sur la courbe de débit, le double déclenchement se caractérise par deux pics inspiratoires (positifs) consécutifs, séparés par un

temps expiratoire (débit négatif) extrêmement bref, voire inexistant. Le volume n'ayant pas eu le temps de sortir, la courbe passe directement d'un débit positif à un autre débit positif.

3.2.3 Corrélation des signaux pour l'Intelligence Artificielle

L'analyse isolée d'un seul signal est souvent insuffisante pour poser un diagnostic de certitude. Par exemple, une encoche sur le débit expiratoire peut être un effort inefficace ou simplement le résultat de sécrétions dans les tuyaux (bruit). C'est la corrélation simultanée des perturbations sur la courbe de débit **et** sur la courbe de pression qui confirme l'asynchronie.

C'est précisément cette analyse multivariée temporelle qui justifie l'utilisation du Deep Learning. Les réseaux de neurones (que nous aborderons dans les chapitres suivants) sont capables de traiter ces deux canaux de données simultanément (P_{aw} et Q), d'extraire des caractéristiques géométriques subtiles invisibles à l'il nu, et de généraliser ces motifs pour classifier chaque cycle avec précision. Les signaux bruts de débit et de pression constituent ainsi la matière première (le Dataset) indispensable à l'entraînement de notre modèle d'intelligence artificielle.

Chapitre 4

Ingénierie des données (Data Pipeline)

La performance d'un modèle d'intelligence artificielle repose fondamentalement sur la qualité et la structuration des données qui le nourrissent. Avant même d'envisager l'entraînement d'un réseau de neurones, il est impératif de construire un "pipeline" de données robuste. Ce chapitre détaille les étapes de traitement informatique développées en Python (via les bibliothèques Pandas et NumPy) pour transformer nos jeux de données en un format mathématique exploitable par l'IA.

4.1 Génération et segmentation du Dataset simulé

4.1.1 L'avantage des données simulées (In Silico)

Les données initiales se présentent sous la forme de multiples fichiers `.csv` contenant des enregistrements à haute fréquence des paramètres ventilatoires (débit, pression dans les voies aériennes, pression musculaire).

Contrairement à des données cliniques acquises directement sur un respirateur de réanimation, notre Dataset est constitué de données simulées. Ce choix méthodologique est stratégique : en clinique, l'évaluation précise de l'effort neural du patient nécessite la pose invasive d'un ballonnet sophagien pour mesurer la pression musculaire (P_{mus}). Grâce à la simulation mathématique et physiologique, nous disposons nativement d'une courbe de P_{mus} parfaite et continue.

La première étape de notre script parcourt automatiquement le répertoire de fichiers simulés. Une vérification d'intégrité est effectuée : les fichiers de simulation ne contenant pas la variable P_{mus} (tels que *Run622.csv* à *Run630.csv*) sont systématiquement ignorés, car cette variable constitue notre repère absolu pour l'étiquetage.




FIGURE 4.1 : Représentation graphique temporelle des données simulées illustrant le Débit, la Pression dans les voies aériennes (P_{aw}) et la Pression musculaire (P_{mus}).

4.1.2 Filtrage et lissage du signal

Même dans un environnement simulé, le traitement numérique requiert une préparation des courbes pour garantir une détection algorithmique sans faille du début et de la fin de chaque respiration. Un lissage mathématique est appliqué au signal de débit (**flow**). Nous avons utilisé une méthode de moyenne mobile centrée (*rolling mean*) sur une fenêtre de 5 échantillons. Cette technique permet de lisser la courbe et d'éliminer les éventuelles variations numériques brusques sans altérer la morphologie globale du cycle respiratoire.

4.1.3 Délimitation automatique des cycles respiratoires

Une fois le signal de débit lissé, l'algorithme procède à la segmentation de la série temporelle continue en cycles individuels. La méthode repose sur la détection du passage à zéro (Zero-crossing) de la courbe de débit. Un cycle démarre lorsque le débit devient positif (début de l'inspiration) et se termine au passage positif suivant. Pour éliminer les micro-segments générés par des oscillations numériques autour du zéro, un filtre de longueur a été implémenté : tout segment comportant moins de 50 points de données est rejeté. Cette extraction nous a permis d'isoler un total massif de **63 857 cycles respiratoires** exploitables.

4.2 Étiquetage (Labeling) et Préparation Tensorielle

4.2.1 Annotation automatisée via la pression musculaire (P_{mus})

L'apprentissage supervisé nécessite que chaque cycle soit accompagné d'une "étiquette" (Label) indiquant s'il est normal ou asynchrone. L'annotation manuelle de près de 64 000 cycles étant impossible, nous avons développé une fonction de labellisation automatique exploitant notre fameuse variable de simulation P_{mus} .

La logique algorithmique compare le temps de cyclage mécanique (défini par le passage du débit en phase expiratoire, c'est-à-dire négative) avec la fin de l'effort neural simulé du patient.

Un effort neural significatif est validé lorsque la P_{mus} franchit un seuil de détection strict fixé à -1.0 cmH₂O. L'algorithme calcule l'écart de temps (Δt) entre la fin de l'insufflation mécanique et la fin de l'effort neural, en appliquant une tolérance de 0.1 seconde (`TOLERANCE_TIME`) :

- **Cycle Normal (None)** : Le décalage est compris dans la zone de tolérance ($-0.1 \text{ s} \leq \Delta t \leq 0.1 \text{ s}$). Le patient simulé et le ventilateur virtuel sont synchronisés.
- **Cyclage Prématuro (Premature)** : La fin de l'assistance mécanique survient trop tôt par rapport à l'effort prolongé du patient ($\Delta t < -0.1 \text{ s}$).
- **Cyclage Retardé (Delayed)** : L'assistance mécanique se prolonge inutilement alors que le patient a terminé son inspiration ($\Delta t > 0.1 \text{ s}$).

4.2.2 Normalisation et mise en forme tensorielle

Les réseaux de neurones exigent des tenseurs (matrices de données) de dimensions strictement identiques en entrée. Or, la durée d'un cycle respiratoire est par nature variable, même en simulation.

Pour uniformiser les données, la classe `AsynchronyDataset` a été développée en PyTorch. Elle impose une longueur maximale de 500 échantillons temporels par cycle (`max_len = 500`) :

- Les cycles plus longs sont **tronqués** à 500 points.
- Les cycles plus courts subissent un **Padding** (remplissage avec des zéros) jusqu'à atteindre la taille requise.

Enfin, seules les variables cliniquement exploitables par le futur réseau (le débit `flow` et la pression `paw`) sont conservées et transposées sous la forme de tenseurs (`Canaux`, `Temps`), générant pour chaque cycle une matrice de taille 2×500 .

Ce format standardisé constitue l'aboutissement du Pipeline. Le jeu de données global de 63 857 cycles est alors divisé de manière stratifiée (pour préserver la proportion des classes) : **80% pour l'entraînement (soit 51 085 cycles)** afin de faire converger le modèle, et **20% pour le test (soit 12 772 cycles)** pour valider ses performances sur des données inédites. Les tenseurs sont désormais prêts à être injectés dans l'architecture Deep Learning.

Chapitre 5

Conception de l'algorithme d'Intelligence Artificielle

L'objectif central de ce projet est de s'affranchir des règles de détection rigides et manuelles pour passer à une approche apprenante. Ce chapitre détaille la conception, l'architecture et la stratégie d'entraînement du modèle d'intelligence artificielle développé. Nous justifierons le choix d'une architecture convolutive unidimensionnelle (1D-CNN) et expliquerons mathématiquement comment le modèle apprend à identifier les asynchronies à partir des signaux de pression et de débit simulés.

5.1 Choix de l'architecture : Le CNN-1D pour séries temporelles

Historiquement, le traitement des séquences temporelles était réservé aux réseaux récurrents (LSTM ou GRU). Cependant, dans le cadre de l'instrumentation biomédicale et du traitement du signal respiratoire, nous avons opté pour une approche par **Convolution Unidimensionnelle (1D-CNN)**.

5.1.1 Avantages par rapport aux réseaux récurrents

Contrairement aux réseaux récurrents qui traitent les données point par point (ce qui est lent et sujet à la disparition du gradient), le CNN-1D traite le signal par "fenêtres" glissantes. Les avantages pour notre projet sont triples :

- **Extraction de caractéristiques locales** : Le CNN est capable de détecter des motifs géométriques précis (comme une encoche sur la pression ou une cassure du débit) indépendamment de leur position exacte dans le cycle.
- **Efficacité computationnelle** : Comme le montre notre terminal, l'utilisation de la technologie CUDA sur GPU permet un calcul parallèle massif. Le CNN est naturellement adapté à cette accélération, rendant l'entraînement beaucoup plus rapide.
- **Invariance spatiale** : Que l'asynchronie survienne au début ou à la fin de l'inspiration, les filtres convolutifs sauront extraire la même signature morphologique.

5.2 Anatomie du modèle CNNRespiratoire

L'architecture que nous avons implémentée dans le script se nomme **CNNRespiratoire**. Elle est structurée en trois blocs de traitement successifs (Extraction de caractéristiques) suivis d'un bloc de classification (Couches denses).

Architecture détaillée du réseau de neurones convolutif 1D (CNN-1D)




FIGURE 5.1 : Architecture détaillée du réseau de neurones convolutif 1D (CNN-1D) conçu pour l'analyse des cycles respiratoires (2 canaux en entrée, 3 classes en sortie).

5.2.1 Les couches de convolution (Feature Extraction)

Comme illustré sur la figure ci-dessus, le modèle reçoit en entrée un tenseur de dimension (2, 500), correspondant aux deux canaux (*Flow* et *Paw*) sur 500 points de temps.

- **Bloc 1 (Conv1D_1)** : 16 filtres de taille 5. Ce premier étage "scanne" le signal pour détecter des motifs de base (pentes, pics).
- **Bloc 2 (Conv1D_2)** : 32 filtres de taille 5. Ce niveau combine les motifs de base pour identifier des formes plus complexes (début d'effort, fin d'insufflation).
- **Bloc 3 (Conv1D_3)** : 64 filtres de taille 3. Ce dernier étage extrait des caractéristiques de haut niveau, prêtes pour la décision finale.

Chaque couche utilise la fonction d'activation **ReLU** (Rectified Linear Unit), définie par $f(x) = \max(0, x)$, qui permet d'introduire la non-linéarité nécessaire à la compréhension de phénomènes physiologiques complexes.

5.2.2 Réduction de dimension et Sous-échantillonnage (Pooling)

Après chaque convolution, nous avons intégré une couche de **MaxPool1D** de taille 2. Le rôle de cette opération est de diviser par deux la résolution temporelle en ne conservant que la valeur maximale de chaque fenêtre. Cela permet non seulement de réduire le nombre de calculs (évitant ainsi le sur-apprentissage), mais aussi de rendre le modèle plus robuste aux petits bruits de signal. À la fin de ces étapes, nos 500 points initiaux sont condensés en 62 vecteurs de caractéristiques de profondeur 64.

5.2.3 La couche dense et la régularisation par Dropout

Une fois les caractéristiques extraites, les données passent dans le bloc de classification entièrement connecté (*Fully Connected Layers*) :

- **Aplatissement (Flattening)** : Les matrices multidimensionnelles sont transformées en un vecteur unique de 3 968 neurones (64×62).
- **Couche Cachée (FC1)** : Un étage de 128 neurones effectue la synthèse finale des informations.
- **Le Dropout (0.5)** : C'est une technique de régularisation cruciale. Durant l'entraînement, 50% des neurones sont désactivés aléatoirement. Cela force le réseau à ne pas dépendre d'un seul chemin de décision et garantit que l'IA pourra généraliser ses connaissances.
- **Sortie (FC2)** : Une couche finale de 3 neurones correspondant à nos probabilités de prédiction : Normal (None), Premature, ou Delayed.

5.3 Stratégie d'entraînement et Optimisation

5.3.1 Fonction de perte : CrossEntropyLoss

Le modèle est entraîné pour minimiser une "fonction de coût". Puisqu'il s'agit d'une classification multiclasse, nous utilisons la **Cross-Entropy**. Mathématiquement, elle mesure l'écart entre la probabilité prédite par l'IA et la classe réelle issue de notre simulation. Plus l'erreur est faible, plus le modèle est "confiant" dans son diagnostic.

5.3.2 Algorithme d'optimisation : Adam

Pour mettre à jour les poids du réseau, nous utilisons l'optimiseur **Adam** avec un taux d'apprentissage (*learning rate*) de 0.001. Adam est une méthode de descente de gradient stochastique qui ajuste automatiquement le pas d'apprentissage pour chaque paramètre, permettant une convergence plus stable et rapide vers la solution optimale.

5.3.3 Hardware et accélération CUDA

Le développement a été réalisé en utilisant l'interface PyTorch `torch.device("cuda")`. Comme indiqué dans notre terminal de sortie, l'appareil utilisé est un processeur graphique (GPU) compatible **NVIDIA CUDA**. Cela permet d'effectuer les multiplications matricielles du CNN de manière hautement parallélisée, rendant possible l'entraînement sur 51 085 cycles en un temps réduit.

5.4 Analyse du processus d'apprentissage

L'entraînement s'est déroulé sur **10 époques**. Une époque correspond à un passage complet du modèle sur l'ensemble des données d'entraînement.

Comme le montre notre historique d'exécution :

- **Époque 1** : L'erreur (*Loss*) initiale est de 0.4225. Le modèle commence à peine à ajuster ses poids.
- **Convergence** : On observe une chute régulière et rapide de la perte. Dès l'époque 3, l'erreur descend sous la barre des 0.20.
- **Époque 10** : Le modèle stabilise son erreur à 0.1255. Cette stabilité indique que l'apprentissage est arrivé à maturité et que le réseau a extrait le maximum d'informations pertinentes du Dataset simulé sans entrer dans une phase de mémorisation excessive (*overfitting*).

Le modèle est alors prêt pour l'étape de validation : l'évaluation sur les 12 772 cycles de test que le réseau n'a pas vus durant l'entraînement. Les performances statistiques de cette prédiction seront détaillées dans le chapitre suivant.

Chapitre 6

PERFORMANCE ET VALIDATION

Introduction

À l'issue de la phase de conception et d'entraînement détaillée dans le chapitre précédent, notre modèle de réseau de neurones convolutif unidimensionnel (1D-CNN) a été soumis à une évaluation rigoureuse. L'objectif de ce chapitre est de quantifier, d'analyser et d'interpréter les performances de l'algorithme sur des données inédites qu'il n'a jamais rencontrées durant sa phase d'apprentissage.

Le pipeline de données a permis d'extraire un total massif de 63 857 cycles respiratoires exploitables à partir des fichiers de simulation. Après une séparation stratifiée, l'entraînement s'est déroulé de manière optimale sur 10 époques. L'historique d'exécution montre une convergence excellente de la fonction de perte (Cross-Entropy Loss), débutant à 0.4354 à la première époque pour se stabiliser à 0.1173 à la dixième époque. Cette stabilité prouve que le modèle a su extraire les motifs géométriques des signaux de pression et de débit sans sombrer dans le sur-apprentissage.

Nous analyserons dans un premier temps les métriques d'évaluation globales, puis nous détaillerons les résultats à travers la matrice de confusion, avant de discuter des perspectives d'interprétabilité du modèle (SHAP et LIME), essentielles pour une intégration clinique réussie.

6.1 Métriques d'évaluation (Précision, Rappel, F1-Score)

Pour évaluer un modèle de classification médicale, l'exactitude globale (Accuracy) ne suffit pas, particulièrement lorsque les classes sont déséquilibrées. Il est impératif de décomposer la performance de l'algorithme à travers des métriques statistiques avancées.

Lors de l'évaluation sur l'ensemble de test (12 772 cycles respiratoires), le rapport de classification a mis en évidence une performance globale exceptionnelle avec une **exactitude (Accuracy) de 96%**.

Il est important de noter une particularité liée à la constitution du jeu de données final : bien que l'architecture du réseau ait été conçue pour prédire 3 classes (Normal, Premature, Delayed), l'application d'un seuil strict de détection de l'effort neural ($P_{mus} \leq -1.0 \text{ cmH}_2\text{O}$) et d'une fenêtre de tolérance temporelle de 0.1 seconde a filtré les asynchronies de type "Delayed" dans le sous-ensemble de test. L'évaluation s'est donc concentrée sur la distinction binaire cruciale entre les cycles synchrones ("None") et les cyclages prématurés ("Premature").

6.1.1 Définitions mathématiques des métriques

Les métriques reposent sur quatre composantes fondamentales issues des prédictions :

- **Vrais Positifs (VP)** : L'IA prédit correctement une asynchronie.

- **Vrais Négatifs (VN)** : L'IA prédit correctement un cycle normal.
- **Faux Positifs (FP)** : L'IA détecte une asynchronie à tort (fausse alarme).
- **Faux Négatifs (FN)** : L'IA manque une asynchronie réelle (sous-diagnostic).

À partir de ces valeurs, nous calculons les métriques suivantes :

1. La Précision (Precision) : Elle mesure la fiabilité de l'alarme déclenchée par l'algorithme.

$$Precision = \frac{VP}{VP + FP}$$

2. Le Rappel ou Sensibilité (Recall) : Il évalue la capacité du modèle à détecter toutes les anomalies existantes sans en oublier.

$$Recall = \frac{VP}{VP + FN}$$

3. Le F1-Score : C'est la moyenne harmonique entre la précision et le rappel. Il offre une vision équilibrée de la performance.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

6.1.2 Analyse des résultats par classe

Les résultats issus du terminal lors de la phase de test révèlent les performances suivantes :

Classe	Précision	Rappel (Recall)	F1-Score	Support (Nombre de cycles)
None (Normal)	0.97	0.98	0.97	9220
Premature	0.94	0.92	0.93	3552
<i>Moyenne macro</i>	0.95	0.95	0.95	12772
<i>Moyenne pondérée</i>	0.96	0.96	0.96	12772

TABLE 6.1 : Rapport de classification généré par l'algorithme 1D-CNN sur l'ensemble de test.

Pour la classe "None" (Cycles normaux) :

Avec un support majoritaire de 9220 cycles, l'algorithme démontre une maîtrise quasi parfaite de la physiologie normale. Le rappel de 98% indique que la quasi-totalité des respirations saines est correctement laissée tranquille par l'algorithme, évitant ainsi de polluer l'environnement de réanimation par de fausses alertes.

Pour la classe "Premature" (Cyclage prématuré) :

Détecter un cyclage prématuré est un défi, car la fin de l'assistance mécanique survient trop tôt par rapport à l'effort prolongé du patient, générant de subtiles variations sur les courbes de débit et de pression. Notre 1D-CNN atteint une précision de 94% et un rappel de 92%. Ce F1-score de 0.93 est remarquable : il signifie que l'IA identifie avec une très haute fiabilité cette frustration inspiratoire, surpassant largement les capacités de l'analyse visuelle humaine continue.

6.2 Analyse de la Matrice de Confusion

La matrice de confusion est l'outil visuel et analytique par excellence pour comprendre la nature exacte des erreurs commises par le réseau de neurones. Contrairement aux métriques globales, elle permet de voir précisément quelles classes sont confondues entre elles.

Vérité Terrain \ Prédictions de l'IA	None	Premature
None	9002 (VN)	218 (FP)
Premature	290 (FN)	3262 (VP)

TABLE 6.2 : Matrice de confusion du réseau CNNRespiratoire.

6.2.1 Interprétation des résultats de la matrice

La matrice de confusion obtenue lors du test sur nos 12 772 cycles s'établit ainsi :

Analyse des diagonales (Les succès) : La diagonale principale regroupe les prédictions correctes. L'algorithme a classé de manière irréprochable 9002 cycles normaux et 3262 asynchronies prématurées. Cela démontre que les couches de convolution (notamment les 64 filtres du dernier bloc d'extraction) ont parfaitement synthétisé les caractéristiques morphologiques des signaux respiratoires.

Analyse des Faux Positifs (218 cycles) : Dans 218 cas, le modèle a signalé une asynchronie "Premature" alors que la simulation étiquetait le cycle comme normal. Cliniquement, ces erreurs "par excès" sont souvent liées à de micro-artefacts sur la courbe de débit, simulant un appel inspiratoire résiduel. En réanimation, un faux positif algorithmique est généralement moins délétère qu'un faux négatif, bien qu'une accumulation excessive puisse causer une "fatigue des alarmes" chez le personnel soignant. Toutefois, 218 erreurs sur 9220 cycles sains représentent un taux d'erreur négligeable de 2.3%.

Analyse des Faux Négatifs (290 cycles) : L'algorithme a manqué 290 asynchronies prématurées, les considérant comme normales. Ces cas correspondent très probablement à des efforts neuraux "à la limite" de notre seuil de tolérance de 0.1 seconde. L'effort du patient dépassant de très peu la fin de l'insufflation, la modification géométrique de la courbe P_{aw} n'était pas assez discriminante pour être captée par le MaxPool1D